Mejorar sobre oclusión sintética no basta: estudio controlado de la transferencia a la oclusión real en la detección de personas

Celia Patricia Apaza Hilasaca, Brayan Raul Condori Quispe, Jhan Logan Ramos Quispe
Universidad Peruana Unión (UPeU), Juliaca, Perú

***Resumen*—El aumento sintético de oclusión se usa para que los detectores de personas resistan la visibilidad parcial, pero su beneficio suele medirse con la misma oclusión artificial. Preguntamos si esa ganancia basta para esperar otra sobre oclusión real de otros conjuntos. En 21 bloques controlados (133 corridas, incluidas las de un planteamiento inicial con un módulo de atención), un modelo base y otro con aumento comparten datos e hiperparámetros; los bloques varían el oclusor, el detector (seis; cuatro con exposición igual, de una y dos etapas), el dominio y la dosis del aumento, y se miden en un control sintético, en dos fuentes de oclusión real anotada (de día y de noche) y en un indicador aproximado en ExDark, con hipótesis registradas internamente con huella criptográfica antes de entrenar. En los 20 bloques con control, el aumento mejora ese control (+2,6 a +60,9 puntos porcentuales, pp, de AP@0.5). Con la dosis habitual y exposición igual (12 bloques), un modelo mixto posterior estima entre $-1{,}1$ y $+1{,}0$ pp según la fuente, poco compatible con una ganancia media de 2 pp. Solo Faster R-CNN con siluetas mejoró dos fuentes reales; con la dosis habitual no volvió a cumplir la regla con cinco semillas, y con una dosis alta mejoró en los mismos pp a las personas sin oclusión. Con 1 183 imágenes de ajuste fino desde COCO, aumento a nivel de píxel y AP@0.5, pasar un control sintético no basta para afirmar robustez a la oclusión real.**

***Palabras clave*—detección de personas, oclusión, aumento de datos, robustez, poca luz, registro interno con huella criptográfica**

I. Introducción

La detección de personas con cámaras RGB se usa en la videovigilancia y la robótica móvil, que también operan de noche. En ese escenario coinciden la oclusión, causa importante de fallos en la detección de peatones [1], y la baja iluminación [2]. En nuestros datos, los modelos base pierden de 0,39 a 0,62 de AP@0.5 en las personas ocluidas frente a las visibles, de día y de noche (sección IV).

Un remedio extendido es el *aumento sintético de oclusión*: durante el entrenamiento se borran o se cubren partes de la persona [3]–[5]. Su beneficio suele medirse sobre la misma oclusión artificial o, cuando se mide sobre oclusión real, dentro del conjunto de entrenamiento (CityPersons, CrowdHuman [6]); rara vez sobre personas realmente ocluidas en otros conjuntos. Si la ganancia sintética no se traslada, los bancos de prueba sintéticos sobreestiman la robustez de los sistemas de vigilancia que se validan con ellos. En el Perú, el serenazgo tenía 14 722 cámaras de videovigilancia operativas en 2023 [7]; sin un conjunto peruano público de personas ocluidas de noche que conozcamos, esos sistemas dependen de modelos entrenados con datos extranjeros, como los de este estudio.

Brecha. En la literatura revisada (sección II) no encontramos un estudio que (i) mida el efecto sobre oclusión real anotada con un control sintético que confirme que el aumento se aprendió, (ii) con varias fuentes reales, (iii) ponga a prueba explicaciones alternativas (oclusor, detector, dominio, exposición, dosis) con experimentos controlados y (iv) fije hipótesis y reglas antes de ver los resultados.

Pregunta, objetivos y contribución. ¿Basta una ganancia sobre oclusión sintética para esperar una ganancia real? El objetivo general es determinar si el aumento sintético de oclusión que mejora un control sintético mejora también la detección de personas realmente ocluidas. Los objetivos específicos son medir la degradación por oclusión del modelo base (OE1, AP@0.5 por estrato); el efecto del aumento (V3$-$V1) según el oclusor y su dosis (OE2), el detector (OE3) y el dominio de entrenamiento (OE4; el volumen de datos solo se exploró); y explorar su mecanismo (OE5: especificidad, caja visible y realismo del oclusor). Aportamos (1) evidencia controlada en 21 bloques con cinco oclusores, seis detectores (cuatro con exposición igual) y tres dosis; (2) un modelo mixto global y un análisis de especificidad que muestran que superar el control sintético no garantiza una mejora real y que la única transferencia que pasa la regla en dos fuentes, con dosis alta y 3 semillas, mejora en los mismos pp a las personas sin oclusión; y (3) un protocolo mínimo (control positivo, V1 y V3 en la misma máquina, épocas fijas, 5 semillas, varias fuentes, especificidad y regla previa), que solo H18a cumple por completo.

II. Trabajos relacionados y marco explicativo

Detección con oclusión y poca luz. Los detectores de peatones atacan la oclusión con la arquitectura y evalúan dentro de un mismo banco: por partes o cajas visibles [8]–[10] o fusionando niveles con Random Erasing [11]; de noche, un YOLOX con transferencia de dominio mejora sin estratificar por oclusión [12].

El aumento como señal de entrenamiento y como prueba. Random Erasing [3] inspiró variantes para peatones evaluadas dentro de CityPersons o CrowdHuman [4], [5]; Copy-Paste [13] y A-Fast-RCNN [14] pegan objetos u ocluyen características sin medir el traslado a otros conjuntos. Los bancos de corrupciones sintéticas [15] miden cuánto resiste el

detector, sin comprobar si lo ganado se traslada. La robustez a cambios sintéticos casi no se traslada a cambios naturales [16]; se traslada en algunos casos [17] y depende de la similitud entre aumento y prueba [18]. La oclusión sintética *ordena* clasificadores ya entrenados de forma parecida a la real [19], y el aumento de oclusión no resuelve la oclusión en pose [20]. En peatones, un aumento por estilización se evaluó entre conjuntos sin estratificar por oclusión [21], y una revisión sitúa el aumento junto a los modelos por partes y la supervisión amodal [22]. Las redes composicionales representan el objeto por partes [23], [24]; WALT aprende representaciones amodales a partir de oclusión real [25]. Como marco usamos el aprendizaje por atajos [26]: una red puede reducir su pérdida aprendiendo el oclusor artificial sin aprender a detectar personas incompletas, y los detectores de peatones ya generalizan mal entre conjuntos [27], [28].

III. Método

Diseño, hipótesis y regla. La unidad de análisis es la celda: un bloque (par V1–V3) evaluado en una fuente. Cada bloque lleva el rótulo de su hipótesis registrada (H3–H18), para rastrearlo hasta el registro. En cada bloque, V1 y V3 comparten datos, hiperparámetros, aumento base y máquina, salvo H16, cuyas V1 son las de H15, entrenadas en otra máquina del mismo modelo; V3 añade el aumento de oclusión solo en el entrenamiento. H3 y H4 predecían que la ganancia sintética se trasladaría a la oclusión real; las hipótesis de transferencia posteriores predicen que no aparece al cambiar el oclusor (H9, H9b, H10, H14; OE2), el detector (H12, H15, H17, y H8 con exposición desigual; OE3), el dominio (H6; OE4), el volumen de datos (H7, exploratorio; OE4) o la dosis (H18; OE2). La predicción se mantiene (transferencia *no detectada*) si menos de dos de las tres fuentes reales *pasan*, es decir, mejoran el AP@0.5 al menos +2 pp (media de semillas) con un IC del 95 % por imágenes que excluye el cero, y el control sintético sí pasa; si no pasa el control, el bloque no es concluyente. H11 predecía lo contrario (ganancia en las personas más ocluidas de CityPersons), H16a y H16b que la transferencia de Faster R-CNN se extendería a otros oclusores, y H13 que los parches serían más distinguibles de la oclusión real que las siluetas, y estas que la difusión (OE5). El programa empezó con H1, H2 y H5, sobre un módulo de atención (CBAM, variantes V2 y V4) y la ganancia sintética de las siluetas: H1 y H2 no se sostuvieron, H5 sí (suplemento), y la pregunta se reorientó a la transferencia. Cada hipótesis, su regla y su código se registraron internamente con una huella criptográfica SHA-256 antes de entrenar su bloque y ninguna se reformuló; la huella permite comprobar que los archivos no cambiaron, pero su fecha la anotó el propio proyecto (sello externo y depósito en Zenodo, DOI 10.5281/zenodo.24122872, solo desde el 10/11/2026). El programa es adaptativo (fig. 1): la pregunta se reorientó tras el primer experimento, H9b–H17 se diseñaron viendo resultados previos y H18 responde a una revisión externa. Lo marcado como posterior no decide ninguna hipótesis.

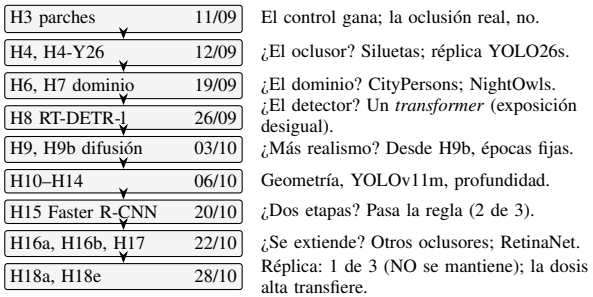


Figura 1. Programa adaptativo: cada bloque responde a una explicación alternativa del anterior (fechas de 2026 en que se fijó la hipótesis).

Datos. ExDark [2], con la partición de Cui et al. [29], tiene 2 658 imágenes con personas; 1 183 se usan para entrenar. Fuentes de oclusión real: (1) NightOwls [30], de noche y desde un vehículo, con el atributo binario de oclusión de sus autores (530 peatones ocluidos en 2 000 fotogramas de validación); (2) CityPersons [31], de día, *heavy* (visibilidad 20–65 %, altura $\geq$50 px); (3) un indicador de oclusión entre personas en ExDark por solapamiento de cajas. El indicador se adoptó después de H3 y H4 (13/09/2026), porque la anotación manual prevista no fue fiable (κ 0,06–0,60 entre pasadas), y, aplicado a CityPersons, concuerda poco con la visibilidad anotada (ρ de Spearman y κ = 0,24); desde H6 se fijó antes de entrenar, y repetimos el análisis sin él (sección IV). Es una fuente secundaria; sigue en la regla «2 de 3» porque así se registró desde H6. CityPersons y NightOwls se puntúan con la caja de cuerpo completo, como en sus protocolos, y ExDark con la de sus anotaciones; la persona ocluida sintéticamente conserva su caja completa y las siluetas de persona pegadas se etiquetan (hasta 0,13, 0,5 y 1,75 personas por imagen según la dosis). Los tres conjuntos se usan bajo licencias de investigación no comercial.

Aumento, dosis y control. Familias de oclusor: parches; siluetas de objetos y personas reales; difusión (Stable Diffusion 1.5 [32]); siluetas con la geometría de visibilidad real de CityPersons; y profundidad (Depth Anything V2 [33]). La dosis habitual ocluye una imagen con probabilidad 0,5, y en ella 1–3 personas con cobertura de 0,30 a 0,85 (0,40–0,95 con la geometría real; en difusión y profundidad, la imagen ocluida sustituye a la original con probabilidad 0,5). H18e cambia solo la dosis de las siluetas: baja (probabilidad 0,25, una persona, cobertura 0,15–0,40) y alta (1,0; 1–6 personas; 0,50–0,95). El *control* aplica el mismo generador a todas las personas de la prueba del dominio de entrenamiento con cobertura de 0,70 a 1,00 y oclusores no vistos; la matriz cruzada usa el control de las demás familias (parámetros en el suplemento).

Detectores y exposición. YOLOv11s, YOLOv11m [34], YOLO26s [35], RT-DETR-l [36] y, de torchvision (ResNet-50 FPN), Faster R-CNN [37] y RetinaNet [38], preentrenados en COCO [39], a 640 px de lado mayor (recetas en el suplemento). En H4, H4-Y26, H6 y H8 cada variante se seleccionó por validación, con exposición *desigual* (V1 en las épocas 1–51, V3 en las 31–89); desde H9b, V1 y V3 se entrenan 30 épocas fijas (60 en H11) y se evalúan con

Tabla I

BLOQUES, HIPÓTESIS Y RESULTADOS: CAMBIO DEL AP@0.5 (PP) DE V3 FRENTE A V1, MEDIA DE 3 SEMILLAS (5 EN H18A). EXP.: EXPOSICIÓN IGUAL (I), DESIGUAL (D) O TEMPRANA (T). NO: NIGHTOWLS OCLUIDOS ($n = 530$); CP: CITYPERSONS *heavy* ($n = 733$); EX: INDICADOR DE EXDARK, FUENTE SECUNDARIA ($n = 101$); CONTROL: 684–2 131 PERSONAS. ENTRE CORCHETES, IC DEL 95 % JERÁRQUICO (SEMILLAS E IMÁGENES). * PASA LA REGLA REGISTRADA (+2 PP, IC POR IMÁGENES > 0), AUNQUE EL IC JERÁRQUICO ENTRE CORCHETES INCLUYA EL CERO. ‡ DESCARTA +2 PP CON EL IC JERÁRQUICO; SIN ‡, «NO DETECTADA» NO PRUEBA AUSENCIA (POTENCIA $\approx 1/3$). CON EL IC DE WELCH ENTRE SEMILLAS, DE LAS 36 CELDAS PRIMARIAS DE DOSIS HABITUAL PASAN 3 Y DESCARTAN +2 PP 11 (SUPLEMENTO). H11: LA CELDA REGISTRADA ERA LA VISIBILIDAD 0,20–0,50 DE CITYPERSONS ($n = 432$), +1,44 [−0,64; +3,34] POR IMÁGENES; LA TABLA DA *heavy*, COMO EN LOS DEMÁS BLOQUES. VEREDICTOS: *No detectada (k de 3)*, PASAN MENOS DE 2 FUENTES; *Detectada*, 2 O 3 (PREDICCIÓN REFUTADA); *No confirmada* O *Refutada*, PREDECÍA GANANCIA O TRANSFERENCIA Y NO LA HUBO; *No concluyente*, SIN CONTROL; *Mismo patrón*, RÉPLICA DE H4; H10-S, BRAZO DE H10. † NO VUELVE A CUMPLIR LA REGLA CON 5 SEMILLAS (H18A).

Bloque	Detector	Entrenamiento	Oclusor	Exp.	Control	NO	CP	EX	Veredicto
Exploratorios: exposición desigual (D) o temprana (T)									
H3	YOLOv11s	ExDark	Parches	T	+60,92*	−3,17 [−7,9; +2,1]	−0,36‡ [−2,4; +1,6]	−3,25‡ [−7,1; +0,9]	No confirmada (predecía ganancia)
H4	YOLOv11s	ExDark	Siluetas	D	+10,63*	−16,79‡ [−20,4; −13,0]	−3,94‡ [−7,1; −1,0]	−5,02‡ [−11,9; +1,3]	No confirmada (predecía ganancia)
H4-Y26	YOLO26s	ExDark	Siluetas	D	+12,01*	−14,31‡ [−18,1; −10,1]	−4,42‡ [−6,9; −1,6]	−3,51‡ [−9,5; +1,9]	Mismo patrón
H6	YOLOv11s	CityPersons	Siluetas	D	+23,74*	−1,35‡ [−3,5; +0,7]	+1,82 [−0,9; +4,4]	+0,94 [−4,1; +6,7]	No detectada (0 de 3)
H7	YOLOv11s	NightOwls 20 000	Siluetas	D	—	−1,43‡ [−4,5; +1,6]	−3,94‡ [−8,2; +0,8]	−9,15‡ [−17,2; −3,3]	No concluyente (sin control)
H8	RT-DETR-l	ExDark	Siluetas	D	+10,97*	−6,98‡ [−11,2; −2,8]	−3,47‡ [−6,3; −0,7]	−2,21 [−7,6; +3,4]	No detectada (0 de 3)
H9	YOLOv11s	ExDark	Difusión	T	+2,60*	−1,93‡ [−3,9; −0,1]	+1,23 [−1,7; +4,0]	+2,82* [−1,2; +7,4]	No detectada (1 de 3)
Evidencia primaria: exposición igual (I)									
H9b	YOLOv11s	ExDark	Difusión	I	+15,23*	+0,01‡ [−1,6; +1,8]	+1,52 [−0,0; +3,4]	−3,03 [−8,8; +2,9]	No detectada (0 de 3)
H10	YOLOv11s	ExDark	Geometría real	I	+18,39*	−2,05‡ [−4,6; +0,3]	+2,37* [+0,6; +4,6]	−4,88‡ [−11,6; +1,0]	No detectada (1 de 3)
H10-s	YOLOv11s	ExDark	Siluetas	I	+10,99*	−1,12‡ [−2,6; +0,5]	+2,26* [+0,7; +4,0]	−3,50‡ [−9,6; +1,9]	(brazo de H10)
H11	YOLOv11s	CityPersons	Siluetas	I	+24,66*	+1,95 [−0,2; +4,7]	+1,31 [−0,8; +3,5]	−2,44 [−7,3; +3,2]	No confirmada (predecía ganancia)
H12a	YOLOv11m	ExDark	Siluetas	I	+14,45*	−0,39 [−3,9; +2,8]	+0,25 [−1,3; +2,1]	+3,04 [−2,6; +8,3]	No detectada (0 de 3)
H12b	YOLOv11m	ExDark	Difusión	I	+19,04*	+0,78 [−3,2; +4,3]	+1,11 [−0,5; +2,9]	−0,56 [−5,8; +5,1]	No detectada (0 de 3)
H14	YOLOv11s	ExDark	Profundidad	I	+7,42*	−1,50‡ [−3,4; +0,3]	−0,16‡ [−1,9; +1,3]	+5,49* [−0,3; +11,1]	No detectada (1 de 3)
H15	Faster R-CNN	ExDark	Siluetas	I	+14,72*	+3,28* [+0,7; +5,8]	+2,33* [+0,1; +4,9]	−1,00 [−6,7; +4,0]	Detectada (2 de 3)†
H16a	Faster R-CNN	ExDark	Difusión	I	+20,35*	+0,92 [−1,6; +3,6]	−0,76‡ [−2,6; +1,2]	+0,80 [−5,1; +6,3]	Refutada (predecía transferencia)
H16b	Faster R-CNN	ExDark	Profundidad	I	+9,63*	+0,37 [−2,1; +2,6]	+0,60 [−1,6; +2,8]	−0,45 [−6,7; +5,6]	Refutada (predecía transferencia)
H17	RetinaNet	ExDark	Siluetas	I	+6,60*	−2,11 [−7,2; +2,8]	−0,28‡ [−2,1; +1,5]	−3,77 [−9,9; +2,8]	No detectada (0 de 3)
Evidencia primaria: réplica de H15 y dosis (H18)									
H18a	Faster R-CNN	ExDark	Siluetas	I	+14,44*	+4,26* [+2,2; +6,3]	+1,74 [−0,1; +3,7]	−2,20 [−6,9; +2,9]	No detectada (1 de 3)
H18e-b	Faster R-CNN	ExDark	Siluetas, dosis baja	I	+2,94*	+2,90* [+0,8; +4,9]	+1,74 [−1,1; +4,1]	−1,91 [−6,6; +3,2]	No detectada (1 de 3)
H18e-a	Faster R-CNN	ExDark	Siluetas, dosis alta	I	+25,62*	+8,59* [+5,7; +11,3]	+3,78* [+0,9; +6,3]	+0,60 [−5,2; +6,5]	Detectada (2 de 3)

los últimos pesos: esos 14 bloques son la evidencia primaria. Cada variante se entrena con 3 semillas y H18a con 5 (H9b y H10-s se extendieron a 5 aparte; aquí se usan sus semillas 0–2). En total hubo 133 corridas y 109 h de GPU (registro en el suplemento); cada bloque de 3 semillas cuesta 0,5–2,6 h en una RTX 4090. RT-DETR-l y YOLO26s solo tienen bloques con exposición desigual (H8, H4-Y26), así que la evidencia primaria cubre cuatro detectores. Máquinas: una laptop con RTX 5050 (8 GB) y, para H11, H12 y H14–H18, una RTX 4090 alquilada. V3 casi no mejora en validación entre las épocas 25 y 30 (<0,6 pp), y H11, con 60 épocas, tampoco transfiere (suplemento).

Evaluación. AP@0.5 de *person* por estrato de oclusión, con los demás estratos como regiones *ignore* [31]; es la única métrica común a las tres fuentes y al control. IC por *bootstrap* sobre imágenes (1 000 réplicas) [40], que decide la regla, y jerárquico sobre semillas e imágenes (2 000), aplicado a todas las celdas. Con 3 semillas solo hay 10 remuestreos distintos de semillas y el IC jerárquico subestima la varianza entre ellas; como sensibilidad damos el IC de la t de Welch con los AP por semilla de V1 y V3 (suplemento). El umbral de +2 pp es el efecto mínimo de interés: equivale, en Faster R-CNN, a unas 17 personas ocluidas más detectadas por cada 1 000 con 0,1 falsos positivos por imagen (análisis posterior), y supera la desviación típica entre semillas de V1 (mediana 1,5 pp). Que no se detecte transferencia no prueba que no exista: con +2 pp verdaderos en las tres fuentes la regla la detecta en uno de cada tres bloques (con +3 pp, en el 94 %). Una celda *descarta* +2 pp si el límite superior de su IC es menor que +2 [41]. Como estimación global (análisis posterior) ajustamos un modelo mixto por REML a las diferencias por semilla: efecto fijo por fuente, efecto aleatorio del bloque y de la semilla dentro del bloque. Sensibilidad: un componente para las V1 compartidas entre bloques y *bootstrap* de bloques; como prueba unilateral de no superioridad, comparamos el límite superior del IC del 90 % con +2 pp. La especificidad (análisis posterior) es la diferencia en pp entre personas ocluidas y sin oclusión, la misma escala de la regla y del umbral de +2 pp; como el AP base de las ocluidas es mucho menor, el suplemento la da también en escala relativa y en tasa de fallos. Secundarias (suplemento), concordantes: con MR^{-2} [1] mejoran 4 de 51 celdas reales (3 en ExDark); con AP@0.5:0.95, ninguna de 24 en los ocho primeros bloques.

IV. RESULTADOS

Degradación (OE1). En los 10 modelos base de ExDark con exposición igual, el AP@0.5 pasa de 0,61–0,69 sin oclusión a 0,15–0,21 en los ocluidos de NightOwls, de 0,47–0,65 a 0,08–0,15 en CityPersons *heavy* y de 0,78–0,85 a 0,20–0,31 en la oclusión severa de ExDark.

Estimación global (OE2–OE4). Todas las cifras son V3−V1 en AP@0.5 (tabla I). Los 20 controles pasan, de +2,6 a +60,9 pp. Con la dosis habitual y exposición igual (12 bloques, 114 diferencias por semilla), el modelo mixto estima

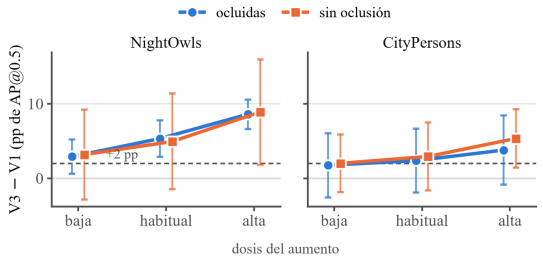


Figura 2. Dosis del aumento (H18, Faster R-CNN, siluetas; semillas 0–2; la tabla I da H18a con 5): V3−V1 en personas ocluidas (en CityPersons, *heavy*) y sin oclusión (*bare*), con IC del 95 % de Welch entre semillas. Discontinua: +2 pp.

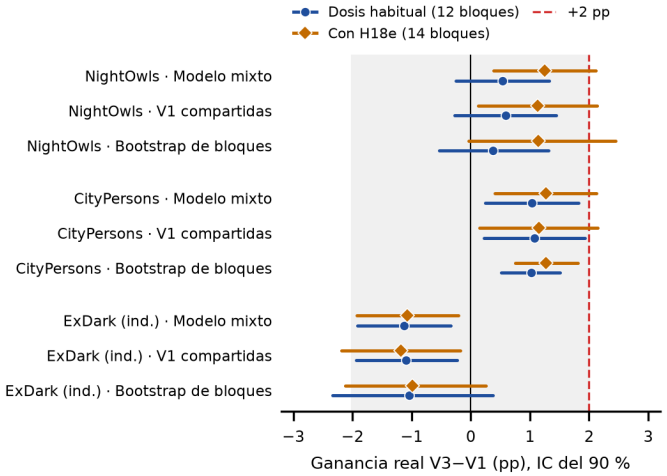


Figura 3. Estimación global V3−V1 por fuente con IC del 90 % (prueba unilateral de no superioridad: límite superior frente a +2 pp; análisis posterior) en tres especificaciones: el modelo mixto del texto, con un componente para las V1 compartidas entre bloques y con *bootstrap* de bloques. Azul: dosis habitual (12 bloques); naranja: con los bloques de dosis H18e (14). Banda gris: ±2 pp.

+0,54 [−0,40; +1,48] en NightOwls, +1,03 [+0,09; +1,97] en CityPersons y −1,13 [−2,08; −0,19] en ExDark (IC del 95 %): con el IC del 90 % (no superioridad; fig. 3), los límites superiores quedan en +1,33, +1,82 y −0,34, poco compatibles con una ganancia media de 2 pp; el de CityPersons queda en +1,93 con V1 compartidas y en +1,51 con *bootstrap* de bloques, así que ninguna especificación alcanza +2 con la dosis habitual. Añadir la ganancia del bloque en su control no cambia la estimación (+0,16 pp por desviación típica [−0,55; +0,87]; dispersión por fuente en el suplemento). Al incluir los bloques de dosis (H18e), los límites superiores al 90 % suben a +2,11 en NightOwls y +2,13 en CityPersons, por encima del umbral. Como descripción, de esas 36 celdas pasan 5 con el IC jerárquico, 9 descartan +2 pp y 22 no son concluyentes (con el IC de Welch, 3, 11 y 22); en todos los bloques con control y dosis habitual pasan 5 de 54, frente a 1,2 esperadas por azar: hay pocas ganancias, pero más que las del azar.

Exposición. Cuando V1 y V3 se seleccionan en épocas distintas, el efecto medio es −4,94 pp; el daño de las siluetas en NightOwls (−16,8 en H4) baja a −1,12 con épocas fijas (H10-s): la exposición desigual explica el daño, pero igualarla no produce ganancia.

Detector, dominio y datos (OE3, OE4). Con exposición igual, el patrón se repite con YOLOv11m (H12); con exposición desigual, RT-DETR-l (H8) y YOLO26s muestran el mismo signo, pero esos bloques no permiten concluir. Faster R-CNN con siluetas (H15) pasa la regla en NightOwls (+3,28) y CityPersons (+2,33), pero con la varianza entre semillas ambos IC incluyen el cero (Welch: [−0,14; +6,71] y [−0,86; +5,52]): el paso estaba dentro del ruido entre semillas, lo que anticipa su réplica. La réplica con 5 semillas en otra máquina (H18a) mantiene NightOwls (+4,26; Welch [+2,63; +5,89]) pero no CityPersons (+1,74 [−0,08; +3,69], compatible con el +2,33 de H15): 1 de 3. Las pruebas para acotar H15 tampoco transfieren: con difusión y profundidad (H16a, H16b), Faster R-CNN aprende el aumento (+20,35 y +9,63) y ninguna celda real supera +0,92, y RetinaNet con siluetas (H17) da 0 de 3, con un V3 que empeora en las tres fuentes reales. Entrenar en el mismo dominio tampoco basta: dentro de CityPersons (H6, H11) el control gana unos +24 y *heavy* menos de +2.

Dosis (OE2). Con Faster R-CNN, la ganancia crece con la dosis en el control (+2,9, +14,8 y +25,6 pp con las semillas 0–2; la tabla da +14,44 con 5), en NightOwls y en CityPersons, y no en ExDark (fig. 2; ExDark en la tabla I). La dosis alta (H18e-a) pasa la regla en dos fuentes; con Welch, solo NightOwls excluye el cero ([+6,61; +10,56]; CityPersons [−0,85; +8,41]). En pp, las personas sin oclusión ganan igual o más (+8,87 y +5,34); en escala relativa la ganancia es mayor en las ocluidas (+60 % frente a +14 % en NightOwls, con AP base 0,14 y 0,63), y en tasa de fallos, menor (suplemento): la especificidad depende de la escala. En ExDark el AP global baja 1,98 pp.

Oclusor (OE2). Ni la difusión, ni la geometría real, ni la profundidad cumplen la regla; en la matriz cruzada entre familias pasan 13 de 20 celdas.

Análisis posteriores (OE5). *Sin ExDark*, exigiendo NightOwls y CityPersons, solo Faster R-CNN con siluetas (H15) y su dosis alta (H18e-a) detectan transferencia; a dosis habitual, solo H15, que no vuelve a cumplir la regla con cinco semillas. *Especificidad* (en pp): restando la ganancia en las personas no ocluidas, de las 6 celdas que pasan la regla (IC de imágenes) en H3–H17, solo las dos del indicador de ExDark son específicas, y ninguna resiste el IC jerárquico. *Caja visible:* puntuando CityPersons con la caja visible, la ganancia en *heavy* no supera +1,3 en ningún bloque de H3–H17 (H15: +0,74): parte de lo ganado es estimar la extensión completa de la persona. *Realismo* (H13, parcialmente confirmada): con DINOv2 [42], los parches se distinguen de la oclusión real más que las siluetas, pero las siluetas no más que la difusión; la oclusión de cada familia se distingue de la real de CityPersons (AUC 0,94–0,99) más que una persona sin ocluir (0,88).

V. Discusión

Como en Taori et al. [16] y Pytel et al. [20], lo ganado frente a una perturbación sintética casi no se traslada a la real; sin contradecir a Kassaw et al. [19] (la oclusión sintética puede ordenar modelos sin bastar para entrenarlos) y, como en

Hendrycks et al. [17] y Mintun et al. [18], el traslado depende del par aumento-prueba y de la dosis. La dosis alta mejora las fuentes externas en personas visibles y ocluidas; lo explicaría una regularización frente al cambio de dominio o el aumento de positivos (hasta $\times$3,5 personas pegadas y etiquetadas, como en Copy-Paste [13]), y ninguna de las dos lecturas es robustez a la oclusión; aun así, una ganancia no específica ayuda a detectar personas ocluidas. La estimación global tampoco es nula en todas las fuentes: en CityPersons hay una ganancia pequeña pero distinta de cero (+1,03 [+0,09; +1,97]) y en el indicador de ExDark un daño ($-$1,13 [$-$2,08; $-$0,19]; negativo en 9 de 12 bloques y con varias familias de oclusor). Una lectura tentativa, que no pusimos a prueba, es que el aumento acerca el modelo a la oclusión pegada y lo aleja de la oclusión entre personas que mide ese indicador. Que pasar el control no baste es compatible con un atajo [26]: el oclusor artificial sigue siendo distinguible del real (H13), aunque no lo pusimos a prueba de forma confirmatoria. Para las 14 722 cámaras del serenazgo [7], validar un modelo solo con oclusión sintética no garantiza que detecte personas ocluidas de noche.

Limitaciones. *Alcance:* 1 183 imágenes de entrenamiento, ajuste fino desde COCO y tres dosis probadas solo con Faster R-CNN y siluetas; a otra escala o con otra dosis el resultado puede cambiar. *Datos:* casi toda la oclusión real está en conjuntos distintos del de entrenamiento; CityPersons es diurno, NightOwls se grabó desde un vehículo y el indicador de ExDark es secundario (III); todo es AP@0.5 de una clase a 640 px. *Detectores y datos:* RT-DETR-l y YOLO26s solo tienen bloques con exposición desigual; un bloque RT-DETR-l con épocas fijas se registró y selló antes de entrenar (H19, 11/11/2026), pero no se ejecutó por presupuesto; el volumen de datos solo se exploró (H7, sin control). *Protocolo:* tres semillas en la mayoría de los bloques, con las que el IC jerárquico es estrecho; celdas y bloques comparten líneas base (sensibilidad en IV), sin corrección por multiplicidad (comparación con el azar en IV); exposición desigual en los primeros bloques; el modelo mixto es posterior, y las huellas solo tienen sello externo (OpenTimestamps) desde el 10/11/2026. *Líneas futuras:* curva de dosis con otros detectores, a mayor escala y sin etiquetar las personas pegadas; oclusión tomada de imágenes reales y supervisión amodal [25]; adaptación de dominio nocturna y arquitecturas por partes [24].

VI. Conclusión

La oclusión real degrada al modelo base en las tres fuentes (OE1). El aumento mejoró la detección sobre oclusión sintética en los 20 bloques con control. Sobre oclusión real, con la dosis habitual y exposición igual (12 bloques), el modelo mixto (posterior) es poco compatible con una ganancia media de 2 pp en las tres fuentes (OE2–OE4), también con V1 compartidas o *bootstrap* de bloques, aunque no al incluir las dosis; la única combinación que pasó la regla, Faster R-CNN con siluetas, no volvió a cumplir la regla con cinco semillas. Una dosis alta sí mejora NightOwls (y CityPersons con el IC por imágenes), pero en los mismos pp a las personas sin oclusión: en diferencia absoluta no es específica de la oclusión, aunque en escala relativa la ganancia es mayor en las ocluidas. El oclusor sintético sigue siendo distinguible del real (OE5). Con aumento a nivel de píxel, 1 183 imágenes de entrenamiento y AP@0.5 de una clase, pasar un control sintético no basta para afirmar robustez a la oclusión real: hace falta oclusión real anotada, V1 y V3 en la misma máquina, cinco semillas, un IC con la varianza entre semillas y un criterio de especificidad con su escala declarada.

Declaraciones

Datos y código. Código, registros, huellas, datos por celda y suplemento (con la búsqueda bibliográfica) en https://github.com/jhanrq8888/argos-occlusion-transfer (público); los pesos de la evidencia primaria (67 corridas, con su SHA-256 en el repositorio) están en Zenodo, DOI 10.5281/zenodo.24120199 (CC BY-NC 4.0). **Financiamiento:** ninguno. **Conflicto de intereses:** ninguno. **Contribuciones (CRediT):** J. L. Ramos Quispe: conceptualización, metodología, software, análisis formal, investigación, curación de datos y redacción del borrador; C. P. Apaza Hilasaca: conceptualización, metodología (diseño de la preespecificación), revisión y edición; B. R. Condori Quispe: curación de datos, validación, visualización, revisión y edición. **Uso de IA:** los autores usaron Scopus AI (Elsevier) para apoyar la búsqueda de los artículos semilla, y Claude (Anthropic) para la búsqueda, el código de análisis y la redacción y edición del texto. Revisaron y verificaron el código, los resultados, las referencias y el texto, de los que asumen la responsabilidad.

Referencias

[1] P. Dollár, C. Wojek, B. Schiele, and P. Perona, "Pedestrian detection: An evaluation of the state of the art," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 34, no. 4, pp. 743–761, 2012, DOI: 10.1109/TPAMI.2011.155.

[2] Y. P. Loh and C. S. Chan, "Getting to know low-light images with the exclusively dark dataset," *Comput. Vis. Image Underst.*, vol. 178, pp. 30–42, 2019, DOI: 10.1016/j.cviu.2018.10.010.

[3] Z. Zhong, L. Zheng, G. Kang, S. Li, and Y. Yang, "Random erasing data augmentation," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 7, 2020, pp. 13 001–13 008, DOI: 10.1609/aaai.v34i07.7000.

[4] C. Shang, H. Ai, Z. Zhuang *et al.*, "Improving pedestrian detection in crowds with synthetic occlusion images," in *Proc. IEEE Int. Conf. Multimedia Expo Workshops (ICMEW)*, 2018, pp. 1–4, DOI: 10.1109/ICMEW.2018.8551575.

[5] C. Chi, S. Zhang, J. Xing, Z. Lei, S. Z. Li, and X. Zou, "PedHunter: Occlusion robust pedestrian detector in crowded scenes," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 7, 2020, pp. 10 639–10 646, DOI: 10.1609/aaai.v34i07.6690.

[6] S. Shao, Z. Zhao, B. Li, T. Xiao, G. Yu, X. Zhang, and J. Sun, "CrowdHuman: A benchmark for detecting human in a crowd," arXiv:1805.00123, 2018.

[7] Instituto Nacional de Estadística e Informática (INEI), "Más de 37 mil efectivos de serenazgo brindaron servicio de seguridad ciudadana," Nota de prensa, 9 abr. 2024, https://www.gob.pe/institucion/inei/noticias/932862, 2024, Registro Nacional de Municipalidades 2023.

[8] S. Zhang, L. Wen, X. Bian, Z. Lei, and S. Z. Li, "Occlusion-aware R-CNN: Detecting pedestrians in a crowd," in *Computer Vision – ECCV 2018*. Springer, 2018, pp. 657–674, DOI: 10.1007/978-3-030-01219-9_39.

[9] C. Zhou and J. Yuan, "Bi-box regression for pedestrian detection and occlusion estimation," in *Computer Vision – ECCV 2018*. Springer, 2018, pp. 138–154, DOI: 10.1007/978-3-030-01246-5_9.

[10] X. Song, B. Chen, P. Li, B. Wang, and H. Zhang, "PRNet++: Learning towards generalized occluded pedestrian detection via progressive refinement network," *Neurocomputing*, vol. 482, pp. 98–115, 2022, DOI: 10.1016/j.neucom.2022.01.056.

[11] R. Huan, J. Zhang, C. Xie, R. Liang, and P. Chen, "MLFFCSP: A new anti-occlusion pedestrian detection network with multi-level feature fusion for small targets," *Multimedia Tools and Applications*, vol. 82, no. 19, pp. 29 405–29 430, 2023, DOI: 10.1007/s11042-023-14721-6.

[12] K. Yi, K. Luo, T. Chen, and R. Hu, "An improved YOLOX model and domain transfer strategy for nighttime pedestrian and vehicle detection," *Applied Sciences*, vol. 12, no. 23, 2022, Art. n.º 12476. DOI: 10.3390/app122312476.

[13] G. Ghiasi, Y. Cui, A. Srinivas, R. Qian, T.-Y. Lin, E. D. Cubuk, Q. V. Le, and B. Zoph, "Simple copy-paste is a strong data augmentation method for instance segmentation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 2917–2927, DOI: 10.1109/CVPR46437.2021.00294.

[14] X. Wang, A. Shrivastava, and A. Gupta, "A-Fast-RCNN: Hard positive generation via adversary for object detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 3039–3048, DOI: 10.1109/CVPR.2017.324.

[15] C. Michaelis, B. Mitzkus, R. Geirhos, E. Rusak, O. Bringmann, A. S. Ecker, M. Bethge, and W. Brendel, "Benchmarking robustness in object detection: Autonomous driving when winter is coming," arXiv:1907.07484, 2019.

[16] R. Taori, A. Dave, V. Shankar, N. Carlini, B. Recht, and L. Schmidt, "Measuring robustness to natural distribution shifts in image classification," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020.

[17] D. Hendrycks, S. Basart, N. Mu, S. Kadavath, F. Wang, E. Dorundo, R. Desai, T. Zhu, S. Parajuli, M. Guo, D. Song, J. Steinhardt, and J. Gilmer, "The many faces of robustness: A critical analysis of out-of-distribution generalization," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2021, pp. 8320–8329, DOI: 10.1109/ICCV48922.2021.00823.

[18] E. Mintun, A. Kirillov, and S. Xie, "On interaction between augmentations and corruptions in natural corruption robustness," arXiv:2102.11273, 2021.

[19] K. Kassaw, F. Luzi, L. M. Collins, and J. M. Malof, "Are deep learning models robust to partial object occlusion in visual recognition tasks?" *Pattern Recognition*, vol. 171, p. 112215, 2026, DOI: 10.1016/j.patcog.2025.112215.

[20] R. Pytel, O. S. Kayhan, and J. C. van Gemert, "Tilting at windmills: Data augmentation for deep pose estimation does not help with occlusions," in *Proc. 25th Int. Conf. Pattern Recognit. (ICPR)*, 2021, pp. 10 568–10 575, DOI: 10.1109/ICPR48806.2021.9412475.

[21] S. Cygert and A. Czyżewski, "Toward robust pedestrian detection with data augmentation," *IEEE Access*, vol. 8, pp. 136 674–136 683, 2020, DOI: 10.1109/ACCESS.2020.3011356.

[22] K. Saleh, S. Szénási, and Z. Vámossy, "Occlusion handling in generic object detection: A review," in *Proc. IEEE SAMI*, 2021, pp. 477–484, DOI: 10.1109/SAMI50585.2021.9378657.

[23] A. Kortylewski, J. He, Q. Liu, and A. L. Yuille, "Compositional convolutional neural networks: A deep architecture with innate robustness to partial occlusion," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 8937–8946, DOI: 10.1109/CVPR42600.2020.00896.

[24] A. Wang, Y. Sun, A. Kortylewski, and A. Yuille, "Robust object detection under occlusion with context-aware CompositionalNets," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 12 642–12 651, DOI: 10.1109/CVPR42600.2020.01266.

[25] N. D. Reddy, R. Tamburo, and S. G. Narasimhan, "WALT: Watch and learn 2D amodal representation from time-lapse imagery," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 9346–9356, DOI: 10.1109/CVPR52688.2022.00914.

[26] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, and F. A. Wichmann, "Shortcut learning in deep neural networks," *Nat. Mach. Intell.*, vol. 2, no. 11, pp. 665–673, 2020, DOI: 10.1038/s42256-020-00257-z.

[27] I. Hasan, S. Liao, J. Li, S. U. Akram, and L. Shao, "Generalizable pedestrian detection: The elephant in the room," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 11 323–11 332, DOI: 10.1109/CVPR46437.2021.01117.

[28] V. S. Sukesh Babu and R. Raman, "Robust pedestrian detection via curated training on created dataset," in *Proc. IEEE 21st India Council Int. Conf. (INDICON)*, 2024, pp. 1–6, DOI: 10.1109/INDICON63790.2024.10958520.

[29] Z. Cui, G.-J. Qi, L. Gu, S. You, Z. Zhang, and T. Harada, "Multitask AET with orthogonal tangent regularity for dark object detection," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2021, pp. 2553–2562, DOI: 10.1109/ICCV48922.2021.00255.

[30] L. Neumann, M. Karg, S. Zhang, C. Scharfenberger, E. Piegert, S. Mistr, O. Prokofyeva, R. Thiel, A. Vedaldi, A. Zisserman, and B. Schiele, "NightOwls: A pedestrians at night dataset," in *Computer Vision – ACCV 2018*, vol. 11361, 2019, pp. 691–705, DOI: 10.1007/978-3-030-20887-5_43.

[31] S. Zhang, R. Benenson, and B. Schiele, "CityPersons: A diverse dataset for pedestrian detection," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, pp. 3213–3221, DOI: 10.1109/CVPR.2017.474.

[32] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 10 674–10 685, DOI: 10.1109/CVPR52688.2022.01042.

[33] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 37, 2024.

[34] Ultralytics, "Ultralytics YOLO11 documentation," https://docs.ultralytics.com/models/yolo11, 2024, Versión 8.4.143. Consultado: jun. 2026.

[35] ——, "Ultralytics YOLO26," https://docs.ultralytics.com/models/yolo26/, 2026, Consultado: 20 oct. 2026.

[36] Y. Zhao, W. Lv, S. Xu, J. Wei, G. Wang, Q. Dang, Y. Liu, and J. Chen, "DETRs beat YOLOs on real-time object detection," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2024, pp. 16 965–16 974, DOI: 10.1109/CVPR52733.2024.01605.

[37] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 39, no. 6, pp. 1137–1149, 2017, DOI: 10.1109/TPAMI.2016.2577031.

[38] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 2999–3007, DOI: 10.1109/ICCV.2017.324.

[39] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: common objects in context," in *Computer Vision – ECCV 2014*, vol. 8693, 2014, pp. 740–755, DOI: 10.1007/978-3-319-10602-1_48.

[40] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall/CRC, 1993.

[41] D. Lakens, "Equivalence tests: A practical primer for t tests, correlations, and meta-analyses," *Soc. Psychol. Personal. Sci.*, vol. 8, no. 4, pp. 355–362, 2017, DOI: 10.1177/1948550617697177.

[42] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov *et al.*, "DINOv2: Learning robust visual features without supervision," *Trans. Mach. Learn. Res.*, 2024.