Mejorar sobre oclusión sintética no basta: estudio controlado de la transferencia a la oclusión real en la detección de personas

Celia Patricia Apaza Hilasaca, Brayan Raul Condori Quispe, Jhan Logan Ramos Quispe
Universidad Peruana Unión (UPeU), Juliaca, Perú

***Resumen*—El aumento sintético de oclusión se usa para que los detectores de personas resistan la visibilidad parcial, pero su beneficio suele medirse con la misma oclusión artificial. Preguntamos si una ganancia sobre oclusión sintética basta para esperar una ganancia sobre oclusión real anotada en otros conjuntos. En 21 bloques controlados (133 corridas), un modelo base y otro con aumento comparten datos e hiperparámetros; los bloques varían el oclusor, el detector (seis, de una y dos etapas y *transformer*), el dominio y la dosis del aumento, y se miden en un control sintético y en tres fuentes de oclusión real, de día y de noche, con hipótesis registradas internamente con huella criptográfica antes de entrenar. Los 20 bloques con control mejoran en él (+2,6 a +60,9 puntos de AP@0.5). Con la dosis habitual y exposición igual (12 bloques), un modelo mixto estima entre −1,1 y +1,1 puntos según la fuente y descarta una ganancia de 2 puntos en las tres. Solo Faster R-CNN mejora dos fuentes reales: con la dosis habitual no se replicó con cinco semillas, y con una dosis alta mejora igual a las personas sin oclusión. Pasar un control sintético no basta para afirmar robustez a la oclusión real.**

***Palabras clave*—detección de personas, oclusión, aumento de datos, robustez, poca luz, hipótesis registradas con huella criptográfica**

I. Introducción

La detección de personas con cámaras RGB sostiene la videovigilancia y la robótica móvil, que también operan de noche. En ese escenario coinciden la oclusión, causa importante de fallos en la detección de peatones [1], y la baja iluminación [2]. En nuestros datos, los modelos base pierden de 0,39 a 0,62 de AP@0.5 en las personas ocluidas frente a las visibles, de día y de noche (sección IV).

Un remedio extendido es el *aumento sintético de oclusión*: durante el entrenamiento se borran o se cubren partes de la persona [3]–[5]. Su beneficio suele medirse sobre la misma oclusión artificial o, cuando se mide sobre oclusión real, dentro del conjunto de entrenamiento (CityPersons, CrowdHuman [6]); rara vez sobre personas realmente ocluidas en otros conjuntos. Si la ganancia sintética no se traslada, los bancos de prueba sintéticos sobreestiman la robustez y un sistema de vigilancia se desplegaría con una robustez que no tiene. En el Perú, el serenazgo municipal tenía 14 722 cámaras de videovigilancia operativas en 2023 [7]; sin un conjunto público peruano de personas ocluidas de noche que conozcamos, dependen de modelos entrenados con otros datos, como este estudio.

Brecha. En la literatura revisada (sección II) no encontramos un estudio que (i) mida el efecto sobre oclusión real anotada con un control sintético que confirme que el aumento se aprendió, (ii) con varias fuentes reales, (iii) ponga a prueba explicaciones alternativas (oclusor, detector, dominio, volumen de datos, exposición, dosis) con experimentos controlados y (iv) fije hipótesis y reglas antes de ver los resultados.

Pregunta, objetivos y contribución. La pregunta es si una ganancia sintética basta para esperar una real. El objetivo general es determinar si el aumento sintético de oclusión que mejora un control sintético mejora también la detección de personas realmente ocluidas. Los objetivos específicos son medir la degradación por oclusión del modelo base (OE1, AP@0.5 por estrato); el efecto del aumento (V3−V1) según el oclusor y su dosis (OE2), el detector (OE3) y el dominio y los datos de entrenamiento (OE4); y explorar su mecanismo (OE5: especificidad, caja visible y realismo del oclusor)[1]. Aportamos (1) evidencia controlada en 21 bloques con cinco oclusores, seis detectores y tres dosis; (2) un modelo mixto global y un análisis de especificidad que muestran que pasar el control sintético no basta y que la única transferencia que pasa la regla en dos fuentes, con dosis alta y 3 semillas, no es específica de la oclusión; y (3) un protocolo mínimo (control positivo, V1 y V3 en la misma máquina, épocas fijas, 5 semillas, varias fuentes reales, especificidad y regla fijada de antemano), que solo H18a cumple entero; cada bloque de 3 semillas cuesta 0,5–2,6 h de GPU en una RTX 4090.

II. Trabajos relacionados y marco explicativo

Detección con oclusión y poca luz. Los detectores de peatones atacan la oclusión con la arquitectura y evalúan dentro de un mismo banco: por partes o cajas visibles [8]–[10] o fusionando niveles con Random Erasing [11]; de noche, un YOLOX con transferencia de dominio mejora sin estratificar por oclusión [12].

El aumento como señal de entrenamiento y como prueba. Random Erasing [3] inspiró variantes para peatones evaluadas dentro de CityPersons o CrowdHuman [4], [5]; Copy-Paste [13] y A-Fast-RCNN [14] pegan objetos u ocluyen características sin medir el traslado a otros conjuntos. Los bancos de corrupciones sintéticas [15] miden lo que el detector

[1]Lo citado como «suplemento», incluida la búsqueda bibliográfica, está en el material suplementario.

aguanta, no si lo ganado se traslada; Taori et al. hallan que la robustez frente a cambios sintéticos casi no pasa a cambios naturales [16], Hendrycks et al. que unas veces sí y otras no [17], y Mintun et al. que la ganancia depende de la similitud entre aumento y prueba [18]. Kassaw et al. encuentran que la oclusión sintética *ordena* a clasificadores ya entrenados de forma parecida a la real [19], y Pytel et al. que el aumento de oclusión no resuelve la oclusión en pose [20]. En peatones, un aumento por estilización se evaluó entre conjuntos sin estratificar por oclusión [21], y una revisión sitúa el aumento junto a los modelos por partes y la supervisión amodal [22].

Alternativas y marco explicativo. Las redes composicionales representan el objeto por partes [23], [24]; WALT aprende representaciones amodales a partir de oclusión real [25]. Como marco usamos el aprendizaje por atajos [26]: una red puede reducir su pérdida aprendiendo el oclusor artificial sin aprender a detectar personas incompletas, y los detectores de peatones ya generalizan mal entre conjuntos [27], [28]. Los cinco artículos semilla salieron de Scopus [10]–[12], [25], [28].

III. Método

Diseño, hipótesis y regla. La unidad de análisis es la celda: un bloque (par V1–V3) evaluado en una fuente. Cada bloque lleva el rótulo de su hipótesis registrada (H3–H18), para rastrearlo hasta el registro. En cada bloque, V1 y V3 comparten datos, hiperparámetros, aumento base y máquina, salvo H16, cuyas V1 son las de H15, entrenadas en otra máquina del mismo modelo; V3 añade el aumento de oclusión solo en el entrenamiento. H3 y H4 predecían que la ganancia sintética se trasladaría a la oclusión real; las hipótesis de transferencia posteriores predicen que no aparece al cambiar el oclusor (H9, H9b, H10, H14; OE2), el detector (H8, H12, H15, H17; OE3), el dominio y los datos (H6, H7; OE4) o la dosis (H18; OE2). La predicción se mantiene (transferencia *no detectada*) si menos de dos de las tres fuentes reales *pasan*, es decir, mejoran el AP@0.5 al menos +2 puntos porcentuales (pp, media de semillas) con un IC del 95 % por imágenes que excluye el cero, y el control sintético sí pasa; si no pasa el control, el bloque no es concluyente. H11 predecía lo contrario (ganancia en las personas más ocluidas de CityPersons), H16a y H16b que la transferencia de Faster R-CNN se extendería a otros oclusores, y H13 un orden de realismo de los oclusores (OE5). Cada hipótesis, su regla y su código se registraron internamente con una huella criptográfica SHA-256 antes de entrenar su bloque y ninguna se reformuló; la huella prueba que nada cambió desde la fecha registrada, pero no hubo registro externo. El programa es adaptativo (fig. 1): la pregunta se reorientó tras el primer experimento, H9b–H17 se diseñaron viendo resultados previos y H18 responde a una revisión externa. Lo marcado como posterior no decide ninguna hipótesis.

Datos. ExDark [2], con la partición de Cui et al. [29], tiene 2 658 imágenes con personas; 1 183 se usan para entrenar. Fuentes de oclusión real: (1) NightOwls [30], de noche y desde un vehículo, con el atributo binario de oclusión de sus autores (530 peatones ocluidos en 2 000 fotogramas de validación); (2)

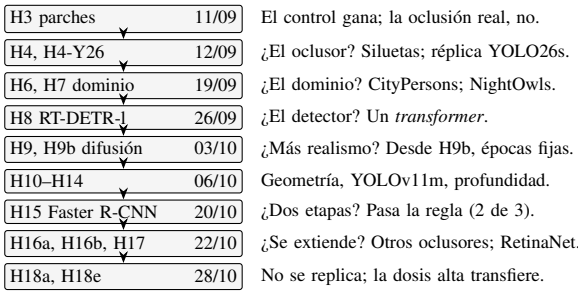


Figura 1. Programa adaptativo: cada bloque responde a una explicación alternativa del anterior (fechas de 2026 en que se fijó la hipótesis).

CityPersons [31], de día, *heavy* (visibilidad 20–65 %, altura $\geq$50 px); (3) un indicador de oclusión entre personas en ExDark por solapamiento de cajas. Es posterior (13/09/2026, tras H3 y H4), porque la anotación manual prevista no fue fiable (κ 0,06–0,60 entre pasadas), y de validez baja (Spearman y κ de 0,24 frente a la visibilidad de CityPersons); desde H6 se fijó antes de entrenar, y repetimos el análisis sin él (sección IV). CityPersons y NightOwls se puntúan con la caja de cuerpo completo, como en sus protocolos, y ExDark con la de sus anotaciones; la persona ocluida sintéticamente conserva su caja completa y las siluetas de persona pegadas se etiquetan. Los tres conjuntos se usan bajo licencias de investigación no comercial.

Aumento, dosis y control. Familias de oclusor: parches; siluetas de objetos y personas reales; difusión (Stable Diffusion 1.5 [32]); siluetas con la geometría de visibilidad real de CityPersons; y profundidad (Depth Anything V2 [33]). La dosis habitual ocluye una imagen con probabilidad 0,5, y en ella 1–3 personas con cobertura de 0,30 a 0,85 (0,40–0,95 con la geometría real; en difusión y profundidad, la imagen ocluida sustituye a la original con probabilidad 0,5). H18e cambia solo la dosis de las siluetas: baja (probabilidad 0,25, una persona, cobertura 0,15–0,40) y alta (1,0; 1–6 personas; 0,50–0,95). El *control* aplica el mismo generador a todas las personas de la prueba del dominio de entrenamiento con cobertura de 0,70 a 1,00 y oclusores no vistos; la matriz cruzada usa el control de las demás familias (parámetros en el suplemento).

Detectores y exposición. YOLOv11s, YOLOv11m [34], YOLO26s [35] (SGD, tasa 0,002, lote 16), RT-DETR-l [36] (AdamW, 10^{-4}) y, de torchvision con la red ResNet-50 FPN, Faster R-CNN [37] y RetinaNet [38] (SGD, lote 8, tasa 0,01 y 0,005), preentrenados en COCO [39]; entrada y evaluación a 640 px de lado mayor. En H4, H4-Y26, H6 y H8 cada variante se seleccionó por validación, con exposición *desigual* (V1 en las épocas 1–51, V3 en las 31–89); desde H9b, V1 y V3 se entrenan 30 épocas fijas (60 en H11) y se evalúan con los últimos pesos: esos 14 bloques son la evidencia primaria. Cada variante se entrena con 3 semillas y H18a con 5 (H9b y H10-s se extendieron a 5 aparte; aquí se usan sus semillas 0–2). En total hubo 133 corridas y 109 h de GPU (registro en el suplemento). Máquinas: una laptop con RTX 5050 (8 GB) y, para H11, H12 y H14–H18, una RTX 4090 alquilada.

Evaluación. AP@0.5 de *person* por estrato de oclusión,

Tabla I

BLOQUES, HIPÓTESIS Y RESULTADOS: CAMBIO DEL AP@0.5 (PP) DE V3 FRENTE A V1, MEDIA DE 3 SEMILLAS (5 EN H18A). EXP.: EXPOSICIÓN AL ENTRENAMIENTO, IGUAL (I, ÉPOCAS FIJAS, EVIDENCIA PRIMARIA), DESIGUAL (D) O TEMPRANA EN AMBAS (T). NO: NIGHTOWLS OCLUIDOS ($n = 530$); CP: CITYPERSONS *heavy* ($n = 733$); EX: INDICADOR DE EXDARK, SEVERA ($n = 101$); CONTROL, 684–2 131 PERSONAS. ENTRE CORCHETES, IC DEL 95 % POR IMÁGENES (1 000 RÉPLICAS). * PASA: +2 PP CON IC > 0. ° NO PASA CON EL IC JERÁRQUICO (SEMILLAS E IMÁGENES), CRITERIO UNIFORME DE SEMILLAS PARA TODAS LAS CELDAS. VEREDICTOS: *No detectada (k de 3)*, PASAN MENOS DE 2 FUENTES; *Detectada*, PASAN 2 O 3 (PREDICCIÓN REFUTADA); *No confirmada* O *Refutada*, PREDECÍA GANANCIA O TRANSFERENCIA Y NO LA HUBO; *No concluyente*, SIN CONTROL; *Mismo patrón*, RÉPLICA DE H4; H10-S, BRAZO DE SILUETAS DE H10. † NO SE REPLICA CON 5 SEMILLAS (H18A).

Bloque	Detector	Entrenamiento	Oclusor	Exp.	Control	NO	CP	EX	Veredicto
H3	YOLOv11s	ExDark	Parches	T	+60,92*	−3,17 [−4,6; −1,7]	−0,36 [−1,1; +0,3]	−3,25 [−5,8; −0,2]	No confirmada (predecía ganancia)
H4	YOLOv11s	ExDark	Siluetas	D	+10,63*	−16,79 [−19,6; −14,0]	−3,94 [−5,7; −2,4]	−5,02 [−10,7; +0,5]	No confirmada (predecía ganancia)
H4-Y26	YOLO26s	ExDark	Siluetas	D	+12,01*	−14,31 [−17,4; −11,1]	−4,42 [−6,0; −2,6]	−3,51 [−8,4; +1,2]	Mismo patrón
H6	YOLOv11s	CityPersons	Siluetas	D	+23,74*	−1,35 [−2,9; +0,2]	+1,82 [+0,3; +3,3]	+0,94 [−2,5; +4,7]	No detectada (0 de 3)
H7	YOLOv11s	NightOwls 20 000	Siluetas	D	—	−1,43 [−4,0; +1,0]	−3,94 [−5,6; −2,3]	−9,15 [−13,9; −5,7]	No concluyente (sin control)
H8	RT-DETR-l	ExDark	Siluetas	D	+10,97*	−6,98 [−8,9; −5,1]	−3,47 [−4,9; −1,8]	−2,21 [−6,2; +1,6]	No detectada (0 de 3)
H9	YOLOv11s	ExDark	Difusión	T	+2,60*	−1,93 [−2,9; −0,9]	+1,23 [+0,4; +2,1]	+2,82*° [+0,4; +6,0]	No detectada (1 de 3)
H9b	YOLOv11s	ExDark	Difusión	I	+15,23*	+0,01 [−1,0; +1,2]	+1,52 [+0,8; +2,7]	−3,03 [−6,8; +1,0]	No detectada (0 de 3)
H10	YOLOv11s	ExDark	Geometría real	I	+18,39*	−2,05 [−3,3; −0,9]	+2,37* [+1,5; +3,5]	−4,88 [−9,1; −0,8]	No detectada (1 de 3)
H10-s	YOLOv11s	ExDark	Siluetas	I	+10,99*	−1,12 [−2,1; +0,1]	+2,26* [+1,4; +3,5]	−3,50 [−7,6; +0,1]	(brazo de H10)
H11	YOLOv11s	CityPersons	Siluetas	I	+24,66*	+1,95 [+0,9; +3,2]	+1,31 [−0,3; +2,8]	−2,44 [−6,8; +2,4]	No confirmada (predecía ganancia)
H12a	YOLOv11m	ExDark	Siluetas	I	+14,45*	−0,39 [−1,6; +0,9]	+0,25 [−0,6; +1,3]	+3,04 [−1,1; +6,6]	No detectada (0 de 3)
H12b	YOLOv11m	ExDark	Difusión	I	+19,04*	+0,78 [−0,4; +2,2]	+1,11 [+0,1; +2,2]	−0,56 [−4,1; +3,2]	No detectada (0 de 3)
H14	YOLOv11s	ExDark	Profundidad	I	+7,42*	−1,50 [−2,8; −0,4]	−0,16 [−1,2; +0,8]	+5,49*° [+1,6; +9,3]	No detectada (1 de 3)
H15	Faster R-CNN	ExDark	Siluetas	I	+14,72*	+3,28* [+1,6; +4,8]	+2,33* [+1,0; +3,7]	−1,00 [−5,6; +3,2]	Detectada (2 de 3)†
H16a	Faster R-CNN	ExDark	Difusión	I	+20,35*	+0,92 [−0,5; +2,3]	−0,76 [−1,8; +0,5]	+0,80 [−3,5; +5,0]	Refutada (predecía transferencia)
H16b	Faster R-CNN	ExDark	Profundidad	I	+9,63*	+0,37 [−1,0; +1,7]	+0,60 [−0,7; +2,0]	−0,45 [−6,2; +4,6]	Refutada (predecía transferencia)
H17	RetinaNet	ExDark	Siluetas	I	+6,60*	−2,11 [−3,5; −0,7]	−0,28 [−1,2; +0,7]	−3,77 [−8,5; +0,8]	No detectada (0 de 3)
H18a	Faster R-CNN	ExDark	Siluetas	I	+14,44*	+4,26* [+2,9; +5,5]	+1,74 [+0,5; +2,9]	−2,20 [−6,1; +1,6]	No detectada (1 de 3)
H18e-b	Faster R-CNN	ExDark	Siluetas, dosis baja	I	+2,94*	+2,90* [+1,7; +4,2]	+1,74 [+0,4; +2,8]	−1,91 [−5,1; +2,0]	No detectada (1 de 3)
H18e-a	Faster R-CNN	ExDark	Siluetas, dosis alta	I	+25,62*	+8,59* [+6,1; +10,6]	+3,78* [+2,1; +5,3]	+0,60 [−4,1; +5,1]	Detectada (2 de 3)

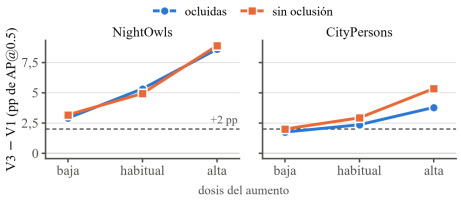


Figura 2. Dosis del aumento (H18, Faster R-CNN, siluetas; semillas 0–2; la tabla I da H18a con 5): V3−V1 en personas ocluidas (en CityPersons, *heavy*) y sin oclusión (*bare*). Discontinua: +2 pp.

con los demás estratos como regiones *ignore* [31]; es la única métrica común a las tres fuentes y al control. IC por *bootstrap* sobre imágenes (1 000 réplicas) [40], que decide la regla, y jerárquico sobre semillas e imágenes (2 000), que aplicamos a todas las celdas como criterio uniforme de varianza entre semillas. El umbral de +2 pp es el efecto mínimo de interés: equivale, en Faster R-CNN, a unas 17 personas ocluidas más detectadas por cada 1 000 con 0,1 falsos positivos por imagen (V1 detecta 91 en CityPersons *heavy* y 196 en NightOwls; análisis posterior), y supera la desviación típica entre semillas de V1 (mediana 1,5 pp). En el texto, los IC de cada celda son jerárquicos; la tabla I da los de imágenes. Que no se detecte transferencia no prueba que no exista: con +2 pp verdaderos en las tres fuentes la regla la detecta en uno de cada tres bloques (con +3 pp, en el 94 %). Una celda *descarta* +2 pp si el límite superior de su IC es menor que +2 [41]. Como estimación global (posterior, añadida tras la revisión externa) ajustamos un modelo mixto por REML a las diferencias por semilla: efecto fijo por fuente, efecto aleatorio del bloque y de la semilla dentro del bloque. Secundarias: MR^{-2} [1] y AP@0.5:0.95 (suplemento).

IV. RESULTADOS

Degradación (OE1). En los 10 modelos base de ExDark con exposición igual, el AP@0.5 pasa de 0,61–0,69 sin oclusión a 0,15–0,21 en los ocluidos de NightOwls, de 0,47–0,65 a 0,08–0,15 en CityPersons *heavy* y de 0,78–0,85 a 0,20–0,31 en la oclusión severa de ExDark.

Estimación global (OE2–OE4). Todas las cifras son V3−V1 en AP@0.5 (tabla I). Los 20 controles pasan, de +2,6 a +60,9 pp. Con la dosis habitual y exposición igual (12 bloques, 114 diferencias por semilla), el modelo mixto estima +0,57 [−0,34; +1,48] en NightOwls, +1,06 [+0,15; +1,96] en CityPersons y −1,11 [−2,01; −0,20] en ExDark: los tres límites superiores quedan por debajo de +2, así que se descarta una ganancia media de 2 pp. Añadir la ganancia del bloque en su control no cambia la estimación (+0,16 pp por desviación típica [−0,46; +0,78]; dispersión por fuente en el suplemento). Con H18e, esos límites suben a +2,27 y +2,29 en NightOwls y CityPersons. Como descripción, de esas 36 celdas pasan 5 con el IC jerárquico, 9 descartan +2 pp y 22 no son concluyentes; en todos los bloques con control y dosis habitual pasan 5 de 54.

Exposición. Con exposición desigual el efecto medio es −4,94 pp; el daño de las siluetas en NightOwls (−16,8 en H4) baja a −1,12 con épocas fijas (H10-s): la exposición explica el daño, no la ausencia de ganancia.

Detector, dominio y datos (OE3, OE4). El patrón se repite con RT-DETR-l (H8), YOLO26s y YOLOv11m (H12). Faster R-CNN con siluetas (H15) pasa la regla en NightOwls (+3,28) y CityPersons (+2,33), también con el IC jerárquico ([+0,67; +5,81] y [+0,13; +4,92]). La réplica con 5 semillas en otra máquina (H18a) mantiene NightOwls (+4,26 [+2,21; +6,32]) pero no CityPersons (+1,74 [−0,08; +3,69], compatible con el

+2,33 de H15): 1 de 3. Las pruebas para acotar H15 tampoco transfieren: con difusión y profundidad (H16a, H16b), Faster R-CNN aprende el aumento (+20,35 y +9,63) y ninguna celda real supera +0,92, y RetinaNet con siluetas (H17) da 0 de 3, con un V3 que empeora en las tres fuentes reales. No es solo el dominio: dentro de CityPersons (H6, H11) el control gana unos +24 y *heavy* menos de +2.

Dosis (OE2). Con Faster R-CNN, la ganancia crece con la dosis en el control (+2,9, +14,8 y +25,6 pp), en NightOwls y en CityPersons, y no en ExDark (fig. 2; ExDark en la tabla I). La dosis alta pasa en dos fuentes, también con el IC jerárquico (H18e-a), pero no es específica de la oclusión: las personas sin oclusión ganan igual o más (+8,87 y +5,34), y en ExDark el AP global baja 1,98 pp.

Oclusor (OE2). Ni la difusión, ni la geometría real, ni la profundidad cumplen la regla; en la matriz cruzada entre familias pasan 13 de 20 celdas.

Análisis posteriores (OE5). *Sin ExDark*, exigiendo NightOwls y CityPersons, solo H15 y H18e-a detectan transferencia; a dosis habitual, solo H15, que no se replica. *Especificidad:* restando la ganancia en las personas no ocluidas, de las 6 celdas que pasan la regla (IC de imágenes) en H3–H17, solo las dos del indicador de ExDark son específicas, y ninguna resiste el IC jerárquico. *Caja visible:* puntuando CityPersons con la caja visible, la ganancia en *heavy* no supera +1,3 en ningún bloque de H3–H17 (H15: +0,74): parte de lo ganado es estimar la extensión completa de la persona. *Realismo* (H13, parcialmente confirmada): con DINOv2 [42], la oclusión de cada familia se distingue de la real de CityPersons (AUC 0,94–0,99) más que una persona sin ocluir (0,88).

V. Discusión

Los resultados coinciden con Taori et al. [16] y Pytel et al. [20]: lo ganado frente a una perturbación sintética casi no pasa a la real. Tampoco contradicen a Kassaw et al. [19]: la oclusión sintética puede ordenar modelos sin bastar para entrenarlos. Como en Hendrycks et al. [17] y Mintun et al. [18], el traslado depende del par aumento-prueba y de la dosis. La dosis alta mejora las fuentes externas tanto en personas visibles como ocluidas. Dos lecturas lo explican y ninguna es robustez a la oclusión: una regularización frente al cambio de dominio, o más positivos, porque la dosis alta multiplica hasta por 3,5 las personas pegadas y etiquetadas, como un aumento Copy-Paste [13]. Que pasar el control no baste es compatible con un atajo [26]: el oclusor artificial sigue siendo distinguible del real (H13), sin prueba confirmatoria. Para las 14 722 cámaras del serenazgo [7], un banco sintético no certifica un modelo para personas ocluidas de noche.

Limitaciones. *Alcance:* 1 183 imágenes de entrenamiento, ajuste fino desde COCO y tres dosis probadas solo con Faster R-CNN y siluetas; a otra escala o con otra dosis el resultado puede cambiar. *Datos:* casi toda la oclusión real está en conjuntos distintos del de entrenamiento; CityPersons es diurno, NightOwls se grabó desde un vehículo y el indicador de ExDark es posterior, de validez baja y $n = 101$; todo es AP@0.5 de una clase a 640 px. *Protocolo:* tres semillas en la mayoría de los bloques; celdas y bloques con líneas base compartidas, dependencia que el modelo mixto no recoge, sin corrección por multiplicidad; exposición desigual en los primeros bloques; el modelo mixto es posterior, y la huella no tiene sello de un tercero (en adelante se sellará con OpenTimestamps).

Líneas futuras. (1) Curva de dosis con otros detectores, a mayor escala y sin etiquetar las personas pegadas. (2) Oclusión tomada de imágenes reales y supervisión amodal [25]. (3) Adaptación de dominio para la noche y arquitecturas por partes [24].

VI. Conclusión

La oclusión real degrada al modelo base en las tres fuentes (OE1). El aumento mejoró la detección sobre oclusión sintética en los 20 bloques con control. Sobre oclusión real, con la dosis habitual y exposición igual (12 bloques), el modelo mixto descarta una ganancia media de 2 pp en las tres fuentes (OE2–OE4); la única combinación que pasó la regla, Faster R-CNN con siluetas, no se replicó con cinco semillas. Una dosis alta sí mejora NightOwls y CityPersons, pero igual en las personas sin oclusión, así que no es robustez específica a la oclusión. El oclusor sintético sigue siendo distinguible del real (OE5). Con aumento a nivel de píxel, 1 183 imágenes de entrenamiento y AP@0.5 de una clase, pasar un control sintético no basta para afirmar robustez a la oclusión real: hace falta oclusión real anotada, V1 y V3 en la misma máquina, cinco semillas y un criterio de especificidad.

Declaraciones

Datos y código. Código, registros, huellas, datos por celda y suplemento en https://github.com/jhanrq8888/argos-occlusion-transfer (público); los pesos entrenados se depositarán con DOI en Zenodo al publicarse. **Financiamiento:** ninguno. **Conflicto de intereses:** ninguno. **Contribuciones (CRediT):** J. L. Ramos Quispe: conceptualización, metodología, software, análisis formal, investigación, curación de datos y redacción del borrador; C. P. Apaza Hilasaca: conceptualización, metodología (diseño de la preespecificación), revisión y edición; B. R. Condori Quispe: curación de datos, validación, visualización, revisión y edición. **Uso de IA:** los autores usaron Scopus AI (Elsevier) para apoyar la búsqueda de los artículos semilla, y Claude (Anthropic) para la búsqueda, el código de análisis y la redacción y edición del texto. Revisaron y verificaron el código, los resultados, las referencias y el texto, de los que asumen la responsabilidad.

Referencias

[1] P. Dollár, C. Wojek, B. Schiele, and P. Perona, "Pedestrian detection: An evaluation of the state of the art," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 34, no. 4, pp. 743–761, 2012, DOI: 10.1109/TPAMI.2011.155.

[2] Y. P. Loh and C. S. Chan, "Getting to know low-light images with the exclusively dark dataset," *Comput. Vis. Image Underst.*, vol. 178, pp. 30–42, 2019, DOI: 10.1016/j.cviu.2018.10.010.

[3] Z. Zhong, L. Zheng, G. Kang, S. Li, and Y. Yang, "Random erasing data augmentation," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 7, 2020, pp. 13 001–13 008, DOI: 10.1609/aaai.v34i07.7000.

[4] C. Shang, H. Ai, Z. Zhuang *et al.*, "Improving pedestrian detection in crowds with synthetic occlusion images," in *Proc. IEEE Int. Conf. Multimedia Expo Workshops (ICMEW)*, 2018, pp. 1–4, DOI: 10.1109/ICMEW.2018.8551575.

[5] C. Chi, S. Zhang, J. Xing, Z. Lei, S. Z. Li, and X. Zou, "PedHunter: Occlusion robust pedestrian detector in crowded scenes," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 7, 2020, pp. 10 639–10 646, DOI: 10.1609/aaai.v34i07.6690.

[6] S. Shao, Z. Zhao, B. Li, T. Xiao, G. Yu, X. Zhang, and J. Sun, "CrowdHuman: A benchmark for detecting human in a crowd," arXiv:1805.00123, 2018.

[7] Instituto Nacional de Estadística e Informática (INEI), "Más de 37 mil efectivos de serenazgo brindaron servicio de seguridad ciudadana," Nota de prensa, 9 abr. 2024, https://www.gob.pe/institucion/inei/noticias/932862, 2024, Registro Nacional de Municipalidades 2023.

[8] S. Zhang, L. Wen, X. Bian, Z. Lei, and S. Z. Li, "Occlusion-aware R-CNN: Detecting pedestrians in a crowd," in *Computer Vision – ECCV 2018*. Springer, 2018, pp. 657–674, DOI: 10.1007/978-3-030-01219-9_39.

[9] C. Zhou and J. Yuan, "Bi-box regression for pedestrian detection and occlusion estimation," in *Computer Vision – ECCV 2018*. Springer, 2018, pp. 138–154, DOI: 10.1007/978-3-030-01246-5_9.

[10] X. Song, B. Chen, P. Li, B. Wang, and H. Zhang, "PRNet++: Learning towards generalized occluded pedestrian detection via progressive refinement network," *Neurocomputing*, vol. 482, pp. 98–115, 2022, DOI: 10.1016/j.neucom.2022.01.056.

[11] R. Huan, J. Zhang, C. Xie, R. Liang, and P. Chen, "MLFFCSP: A new anti-occlusion pedestrian detection network with multi-level feature fusion for small targets," *Multimedia Tools and Applications*, vol. 82, no. 19, pp. 29 405–29 430, 2023, DOI: 10.1007/s11042-023-14721-6.

[12] K. Yi, K. Luo, T. Chen, and R. Hu, "An improved YOLOX model and domain transfer strategy for nighttime pedestrian and vehicle detection," *Applied Sciences*, vol. 12, no. 23, 2022, Art. n.º 12476. DOI: 10.3390/app122312476.

[13] G. Ghiasi, Y. Cui, A. Srinivas, R. Qian, T.-Y. Lin, E. D. Cubuk, Q. V. Le, and B. Zoph, "Simple copy-paste is a strong data augmentation method for instance segmentation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 2917–2927, DOI: 10.1109/CVPR46437.2021.00294.

[14] X. Wang, A. Shrivastava, and A. Gupta, "A-Fast-RCNN: Hard positive generation via adversary for object detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 3039–3048, DOI: 10.1109/CVPR.2017.324.

[15] C. Michaelis, B. Mitzkus, R. Geirhos, E. Rusak, O. Bringmann, A. S. Ecker, M. Bethge, and W. Brendel, "Benchmarking robustness in object detection: Autonomous driving when winter is coming," arXiv:1907.07484, 2019.

[16] R. Taori, A. Dave, V. Shankar, N. Carlini, B. Recht, and L. Schmidt, "Measuring robustness to natural distribution shifts in image classification," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020.

[17] D. Hendrycks, S. Basart, N. Mu, S. Kadavath, F. Wang, E. Dorundo, R. Desai, T. Zhu, S. Parajuli, M. Guo, D. Song, J. Steinhardt, and J. Gilmer, "The many faces of robustness: A critical analysis of out-of-distribution generalization," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2021, pp. 8320–8329, DOI: 10.1109/ICCV48922.2021.00823.

[18] E. Mintun, A. Kirillov, and S. Xie, "On interaction between augmentations and corruptions in natural corruption robustness," arXiv:2102.11273, 2021.

[19] K. Kassaw, F. Luzi, L. M. Collins, and J. M. Malof, "Are deep learning models robust to partial object occlusion in visual recognition tasks?" *Pattern Recognition*, vol. 171, p. 112215, 2026, DOI: 10.1016/j.patcog.2025.112215.

[20] R. Pytel, O. S. Kayhan, and J. C. van Gemert, "Tilting at windmills: Data augmentation for deep pose estimation does not help with occlusions," in *Proc. 25th Int. Conf. Pattern Recognit. (ICPR)*, 2021, pp. 10 568–10 575, DOI: 10.1109/ICPR48806.2021.9412475.

[21] S. Cygert and A. Czyżewski, "Toward robust pedestrian detection with data augmentation," *IEEE Access*, vol. 8, pp. 136 674–136 683, 2020, DOI: 10.1109/ACCESS.2020.3011356.

[22] K. Saleh, S. Szénási, and Z. Vámossy, "Occlusion handling in generic object detection: A review," in *Proc. IEEE SAMI*, 2021, pp. 477–484, DOI: 10.1109/SAMI50585.2021.9378657.

[23] A. Kortylewski, J. He, Q. Liu, and A. L. Yuille, "Compositional convolutional neural networks: A deep architecture with innate robustness to partial occlusion," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 8937–8946, DOI: 10.1109/CVPR42600.2020.00896.

[24] A. Wang, Y. Sun, A. Kortylewski, and A. Yuille, "Robust object detection under occlusion with context-aware CompositionalNets," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 12 642–12 651, DOI: 10.1109/CVPR42600.2020.01266.

[25] N. D. Reddy, R. Tamburo, and S. G. Narasimhan, "WALT: Watch and learn 2D amodal representation from time-lapse imagery," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 9346–9356, DOI: 10.1109/CVPR52688.2022.00914.

[26] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, and F. A. Wichmann, "Shortcut learning in deep neural networks," *Nat. Mach. Intell.*, vol. 2, no. 11, pp. 665–673, 2020, DOI: 10.1038/s42256-020-00257-z.

[27] I. Hasan, S. Liao, J. Li, S. U. Akram, and L. Shao, "Generalizable pedestrian detection: The elephant in the room," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 11 323–11 332, DOI: 10.1109/CVPR46437.2021.01117.

[28] V. S. Sukesh Babu and R. Raman, "Robust pedestrian detection via curated training on created dataset," in *Proc. IEEE 21st India Council Int. Conf. (INDICON)*, 2024, pp. 1–6, DOI: 10.1109/INDICON63790.2024.10958520.

[29] Z. Cui, G.-J. Qi, L. Gu, S. You, Z. Zhang, and T. Harada, "Multitask AET with orthogonal tangent regularity for dark object detection," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2021, pp. 2553–2562, DOI: 10.1109/ICCV48922.2021.00255.

[30] L. Neumann, M. Karg, S. Zhang, C. Scharfenberger, E. Piegert, S. Mistr, O. Prokofyeva, R. Thiel, A. Vedaldi, A. Zisserman, and B. Schiele, "NightOwls: A pedestrians at night dataset," in *Computer Vision – ACCV 2018*, vol. 11361, 2019, pp. 691–705, DOI: 10.1007/978-3-030-20887-5_43.

[31] S. Zhang, R. Benenson, and B. Schiele, "CityPersons: A diverse dataset for pedestrian detection," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, pp. 3213–3221, DOI: 10.1109/CVPR.2017.474.

[32] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 10 674–10 685, DOI: 10.1109/CVPR52688.2022.01042.

[33] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 37, 2024.

[34] Ultralytics, "Ultralytics YOLO11 documentation," https://docs.ultralytics.com, 2024, Consultado: jun. 2026.

[35] ——, "Ultralytics YOLO26," https://docs.ultralytics.com/models/yolo26/, 2026, Consultado: 20 oct. 2026.

[36] Y. Zhao, W. Lv, S. Xu, J. Wei, G. Wang, Q. Dang, Y. Liu, and J. Chen, "DETRs beat YOLOs on real-time object detection," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2024, pp. 16 965–16 974, DOI: 10.1109/CVPR52733.2024.01605.

[37] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 39, no. 6, pp. 1137–1149, 2017, DOI: 10.1109/TPAMI.2016.2577031.

[38] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 2999–3007, DOI: 10.1109/ICCV.2017.324.

[39] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: common objects in context," in *Computer Vision – ECCV 2014*, vol. 8693, 2014, pp. 740–755, DOI: 10.1007/978-3-319-10602-1_48.

[40] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall/CRC, 1993.

[41] D. Lakens, "Equivalence tests: A practical primer for t tests, correlations, and meta-analyses," *Soc. Psychol. Personal. Sci.*, vol. 8, no. 4, pp. 355–362, 2017, DOI: 10.1177/1948550617697177.

[42] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov *et al.*, "DINOv2: Learning robust visual features without supervision," *Trans. Mach. Learn. Res.*, 2024.