Mejorar sobre oclusión sintética no basta: aumento de oclusión y oclusión real en la detección de personas

Celia Patricia Apaza Hilasaca, Brayan Raul Condori Quispe, Jhan Logan Ramos Quispe
Universidad Peruana Unión (UPeU), Juliaca, Perú

***Resumen*—El aumento sintético de oclusión se usa para que los detectores de personas resistan la visibilidad parcial, pero su beneficio suele medirse con la misma oclusión artificial. Preguntamos si una ganancia sobre oclusión sintética basta para esperar una ganancia sobre oclusión real anotada por humanos en otros conjuntos de datos. Comparamos un modelo base y otro con aumento, con los mismos datos e hiperparámetros, en 18 bloques que varían el oclusor (parches, siluetas, difusión, geometría real y orden de profundidad), el detector (YOLOv11 en dos tamaños, YOLO26s, RT-DETR-l, RetinaNet y Faster R-CNN) y el dominio de entrenamiento (117 corridas, ajuste fino desde COCO). Cada bloque se mide en su control sintético (17 de 18) y en tres fuentes de oclusión real, de día y de noche; hipótesis y reglas se fijaron antes de entrenar cada bloque, en un registro interno de un programa adaptativo. Una celda pasa si mejora al menos 2 puntos de AP@0.5 con un intervalo del 95 % que excluye el cero. Los 17 controles pasan (+2,6 a +60,9). En el recuento primario, con exposición igual al entrenamiento (33 celdas reales), pasan 5, 15 descartan +2 puntos y 13 no son concluyentes; la ganancia media es +0,96 [+0,34; +1,56] en CityPersons, +0,01 en NightOwls y $-0{,}94$ en ExDark. Solo Faster R-CNN con siluetas cumple la regla en dos fuentes; en análisis posteriores, su ganancia no es claramente mayor en las personas ocluidas, es frágil frente a la varianza entre semillas, en CityPersons baja a +0,7 al puntuar la caja visible y con MR^{-2} mejora menos de 2 puntos. Pasar un control sintético no basta para afirmar robustez a la oclusión real.**

***Palabras clave*—detección de personas, oclusión, aumento de datos, robustez, poca luz, hipótesis preespecificadas**

I. Introducción

La detección de personas con cámaras RGB apoya la vigilancia y la robótica móvil. La oclusión, causa importante de fallos en la detección de peatones [**?**], y la baja iluminación [**?**] suelen coincidir de noche. En nuestros datos, un YOLOv11s ajustado sobre ExDark cae de 0,82 de AP@0.5 en personas sin oclusión a 0,24 en personas con oclusión severa entre personas.

Un remedio extendido es el *aumento sintético de oclusión*: durante el entrenamiento se borran o se cubren partes de la persona [**?**], [**?**], [**?**]. Su beneficio suele medirse sobre la misma oclusión artificial o, cuando se mide sobre oclusión real, dentro del conjunto de entrenamiento (CityPersons, CrowdHuman [**?**]); rara vez sobre personas realmente ocluidas en otros conjuntos. Si la ganancia sintética no se traslada, los bancos de prueba sintéticos sobreestiman la robustez.

Brecha. En la literatura revisada (sección II) no encontramos un estudio que (i) mida el efecto sobre oclusión real anotada con un control sintético que confirme que el aumento se aprendió, (ii) con varias fuentes reales, (iii) ponga a prueba explicaciones alternativas (oclusor, detector, dominio, volumen de datos, exposición) con experimentos controlados y (iv) fije hipótesis y reglas antes de ver los resultados.

Objetivos y contribución. Los objetivos son medir la degradación por oclusión (OE1), el efecto del aumento sobre la oclusión sintética y la real según el oclusor (OE2), el detector (OE3) y el dominio y los datos (OE4), y su mecanismo (OE5)[1]. Aportamos (1) evidencia controlada en 18 bloques con cinco tipos de oclusor y seis detectores (de una y dos etapas y *transformer*); (2) un recuento primario con intervalos, separado por exposición al entrenamiento, con análisis de especificidad (ocluidas frente a visibles) y de convención de cajas, que muestra que pasar el control sintético no basta; y (3) un protocolo mínimo reutilizable: control positivo con oclusores no vistos; V1 y V3 en la misma máquina y versión de software; épocas fijas; al menos 5 semillas, con IC que incluyan su varianza; fuentes reales del mismo dominio y de otros; especificidad; y regla fijada de antemano. Cuesta 0,5–2,6 h de GPU por bloque.

II. Trabajos relacionados y marco explicativo

Detección con oclusión y poca luz. Los detectores de peatones atacan la oclusión con la arquitectura y evalúan dentro de un mismo banco: por partes o con cajas visibles [**?**], [**?**], refinando anclas desde las partes visibles en CityPersons, Caltech y ECP-night [**?**], o fusionando niveles con Random Erasing [**?**]. Para la noche, un YOLOX con transferencia de dominio sube el mAP 5,9 puntos sin estratificar por oclusión [**?**].

El aumento como señal de entrenamiento y como prueba. Random Erasing [**?**] inspiró variantes para peatones evaluadas dentro de CityPersons o CrowdHuman [**?**], [**?**]; Copy-Paste pega objetos sin modelar el contexto [**?**], y A-Fast-RCNN genera oclusión adversaria sobre las características de un detector de dos etapas [**?**]. En robustez, los bancos de corrupciones sintéticas para detección [**?**] miden lo que el modelo aguanta, no si lo ganado se traslada; Taori et al. hallan que la robustez frente a cambios sintéticos casi no pasa a cambios naturales [**?**], Hendrycks et al. que unas veces sí y otras no [**?**], y Mintun et al. que la ganancia depende de la

[1]La correspondencia entre objetivos, método, evidencia y pendientes, la búsqueda bibliográfica y todo el material citado como «suplemento» están en el material suplementario.

similitud entre aumento y prueba [**?**]. Kassaw et al. encuentran que la oclusión sintética *ordena* a clasificadores ya entrenados de forma parecida a la real [**?**], y Pytel et al. que el aumento de oclusión no resuelve la oclusión en pose [**?**]. Frente a Taori et al., aquí el cambio natural es la oclusión anotada, la tarea es detección y un control positivo confirma en cada bloque que el aumento se aprendió.

Alternativas y marco explicativo. Las redes composicionales representan el objeto por partes [**?**], [**?**]; WALT aprende representaciones amodales a partir de oclusión real [**?**]. No evaluamos esas vías: el estudio se limita al aumento a nivel de píxel sobre RGB. Como marco usamos el aprendizaje por atajos [**?**]: una red puede reducir su pérdida aprendiendo el oclusor artificial sin aprender a detectar personas incompletas, y los detectores de peatones ya generalizan mal entre conjuntos [**?**], [**?**]. La búsqueda partió de Scopus, de donde salieron los cinco artículos semilla [**?**], [**?**], [**?**], [**?**], [**?**].

III. Método

Diseño, hipótesis y regla. En cada bloque, el modelo base (V1) y el aumentado (V3) comparten datos, hiperparámetros, aumento base y máquina, salvo H16, cuyas V1 son las de H15, entrenadas en otra máquina del mismo modelo; V3 añade el aumento de oclusión solo en el entrenamiento. Las hipótesis de transferencia predicen que el déficit persiste. La predicción se mantiene (transferencia *no detectada*) si menos de dos de las tres fuentes reales *pasan*, es decir, mejoran el AP@0.5 al menos +2 puntos porcentuales (pp, media de semillas) con un IC del 95 % por imágenes que excluye el cero, y el control sintético sí pasa; si no pasa el control, el bloque no es concluyente. H11 predecía lo contrario (ganancia en las personas más ocluidas), H16a y H16b que la transferencia de Faster R-CNN se extendería a otros oclusores, y H13 un orden de realismo. El planteamiento original incluía un módulo de atención (V2 y V4; H1, H2 y H5), sin ganancia en oclusión real (suplemento). Cada hipótesis, su regla y su código se fijaron con una huella criptográfica SHA-256 antes de entrenar su bloque y ninguna se reformuló; la huella prueba que nada cambió desde la fecha registrada por el proyecto, pero no hubo registro externo. La pregunta se reorientó tras el primer experimento y H9b–H17 se diseñaron viendo resultados previos: el programa es adaptativo. Todo lo marcado como posterior se declaró después de ver los resultados y no decide ninguna hipótesis.

Datos. ExDark [**?**], con la partición de Cui et al. [**?**], tiene 2 658 imágenes con personas; 1 183 se usan para entrenar. Fuentes de oclusión real: (1) NightOwls [**?**], de noche y desde un vehículo, con el atributo binario de oclusión de sus autores (530 peatones ocluidos en 2 000 fotogramas de validación); (2) CityPersons [**?**], de día, *heavy* (visibilidad 20–65 %, altura $\geq$50 px, 733 instancias); (3) un indicador de oclusión entre personas en ExDark por solapamiento de cajas (101 instancias severas; Spearman 0,24 con la visibilidad anotada de CityPersons). CityPersons y NightOwls se puntúan con la caja de cuerpo completo, como en sus protocolos, y ExDark con la caja de sus anotaciones; la persona ocluida sintéticamente conserva su caja completa y las siluetas de persona pegadas se etiquetan. La gradación visual manual se descartó (κ de 0,06 a 0,60). Los tres conjuntos se usan bajo licencias de investigación no comercial.

Aumento y control. Familias de oclusor: parches opacos o con textura; siluetas recortadas de objetos y personas reales; oclusores pintados por Stable Diffusion 1.5 [**?**]; siluetas con patrones de visibilidad reales de CityPersons; y objetos delante de la persona según la profundidad de Depth Anything V2 [**?**]. V3 ocluye 1–3 personas por imagen con cobertura de 0,30 a 0,85. El *control* aplica el mismo generador a todas las personas de la prueba del dominio de entrenamiento (ExDark test; CityPersons en H6 y H11) con cobertura de 0,70 a 1,00 y oclusores no vistos; la matriz cruzada evalúa cada familia en el control de las demás.

Detectores y exposición. YOLOv11s, YOLOv11m [**?**], YOLO26s [**?**] (SGD, tasa 0,002, lote 16), RT-DETR-l [**?**] (AdamW, 10^{-4}) y, de torchvision con la red ResNet-50 FPN, Faster R-CNN [**?**] y RetinaNet [**?**] (SGD, lote 8, tasa de referencia escalada al lote: 0,01 y 0,005), preentrenados en COCO [**?**]; entrada y evaluación a 640 px de lado mayor (un peatón de 50 px de CityPersons queda en unos 16). En H4, H4-Y26, H6 y H8 cada variante se seleccionó por validación, con exposición *desigual* (V1 en las épocas 1–51, V3 en las 31–89); desde H9b, V1 y V3 se entrenan épocas fijas y se evalúan con los últimos pesos: esos 11 bloques son la evidencia primaria. Máquinas: una laptop con NVIDIA GeForce RTX 5050 Laptop GPU (8 GB) y, para H11, H12 y H14–H17, una RTX 4090 alquilada.

Evaluación. AP@0.5 de *person* por estrato de oclusión, con los demás estratos como regiones *ignore* [**?**]; es la métrica primaria por ser la única común a las tres fuentes y al control. IC por *bootstrap* sobre imágenes (1 000 réplicas) [**?**] y jerárquico sobre semillas e imágenes (2 000), que con 3 semillas subestima la varianza entre semillas. El umbral de +2 pp es el efecto mínimo de interés: supera la desviación típica entre semillas de V1 (mediana 1,5 pp). Una celda *descarta* +2 pp si el límite superior de su IC es menor que +2 [**?**]. Secundarias: MR^{-2} [**?**] (FPPI de 10^{-2} a 10^{0}, mismas regiones *ignore*) y AP@0.5:0.95 (suplemento).

IV. Resultados

Recuento primario. Todas las cifras son V3$-$V1 en AP@0.5 (tabla I). Los 17 controles pasan, de +2,6 a +60,9 pp. Con exposición igual (11 bloques, 33 celdas reales) pasan 5 (4 con el IC jerárquico), 15 descartan +2 pp (9) y 13 no son concluyentes. La ganancia media por fuente, con IC *bootstrap* de bloques, es +0,96 [+0,34; +1,56] en CityPersons (8 de 11 bloques positivos), +0,01 [$-$0,92; +0,97] en NightOwls y $-$0,94 [$-$2,55; +0,94] en ExDark; con efectos aleatorios, CityPersons y NightOwls quedan dentro de $\pm$2 pp (IC 90 %), ExDark no. Con los 17 bloques pasan 6 de 51 celdas (marcadas en la tabla I) y 29 descartan +2 pp; sin el indicador de ExDark pasan 4 de 34 y solo H15 alcanza dos fuentes.

La exposición explica el daño, no la ausencia de ganancia. Con exposición desigual (12 celdas) el efecto medio es $-$4,94 pp, frente a +0,01 con exposición igual. El daño de las

Tabla I

BLOQUES, HIPÓTESIS Y RESULTADOS: CAMBIO DEL AP@0.5 (PP) DE V3 FRENTE A V1, MEDIA DE 3 SEMILLAS. EXP.: EXPOSICIÓN AL ENTRENAMIENTO, IGUAL (I, ÉPOCAS FIJAS, EVIDENCIA PRIMARIA), DESIGUAL (D) O TEMPRANA EN AMBAS (T). NO: NIGHTOWLS OCLUIDOS; CP: CITYPERSONS *heavy*; EX: INDICADOR DE EXDARK, SEVERA. * PASA (+2 PP CON IC POR IMÁGENES > 0). NO DETECTADA: MENOS DE 2 FUENTES PASAN; NO PRUEBA AUSENCIA, PORQUE CON +2 PP VERDADEROS EN LAS TRES FUENTES LA REGLA DETECTA LA TRANSFERENCIA EN UNO DE CADA TRES BLOQUES (CON +3 PP, EN EL 94 %). † NO RESISTE LA VARIANZA ENTRE SEMILLAS, LA ESPECIFICIDAD NI LA CAJA VISIBLE (SECCIÓN IV). IC DE CADA CELDA EN EL SUPLEMENTO.

Bloque	**Detector**	**Entrenamiento**	**Oclusor**	**Exp.**	**Control**	**NO**	**CP**	**EX**	**Veredicto**
H3	YOLOv11s	ExDark	Parches	T	+60,92*	−3,17	−0,36	−3,25	No confirmada (predecía ganancia)
H4	YOLOv11s	ExDark	Siluetas	D	+10,63*	−16,79	−3,94	−5,02	No confirmada (predecía ganancia)
H4-Y26	YOLO26s	ExDark	Siluetas	D	+12,01*	−14,31	−4,42	−3,51	Mismo patrón
H6	YOLOv11s	CityPersons	Siluetas	D	+23,74*	−1,35	+1,82	+0,94	No detectada (0 de 3)
H7	YOLOv11s	NightOwls 20 000	Siluetas	D	—	−1,43	−3,94	−9,15	No detectada (sin control)
H8	RT-DETR-l	ExDark	Siluetas	D	+10,97*	−6,98	−3,47	−2,21	No detectada (0 de 3)
H9	YOLOv11s	ExDark	Difusión	T	+2,60*	−1,93	+1,23	+2,82*	No detectada (1 de 3)
H9b	YOLOv11s	ExDark	Difusión	I	+15,23*	+0,01	+1,52	−3,03	No detectada (0 de 3)
H10	YOLOv11s	ExDark	Geometría real	I	+18,39*	−2,05	+2,37*	−4,88	No detectada (1 de 3)
H10-s	YOLOv11s	ExDark	Siluetas	I	+10,99*	−1,12	+2,26*	−3,50	(brazo de comparación de H10)
H11	YOLOv11s	CityPersons	Siluetas	I	+24,66*	+1,95	+1,31	−2,44	No confirmada (predecía ganancia)
H12a	YOLOv11m	ExDark	Siluetas	I	+14,45*	−0,39	+0,25	+3,04	No detectada (0 de 3)
H12b	YOLOv11m	ExDark	Difusión	I	+19,04*	+0,78	+1,11	−0,56	No detectada (0 de 3)
H14	YOLOv11s	ExDark	Profundidad	I	+7,42*	−1,50	−0,16	+5,49*	No detectada (1 de 3)
H15	Faster R-CNN	ExDark	Siluetas	I	+14,72*	+3,28*	+2,33*	−1,00	Pasa la regla (2 de 3)†
H16a	Faster R-CNN	ExDark	Difusión	I	+20,35*	+0,92	−0,76	+0,80	Refutada (predecía transferencia)
H16b	Faster R-CNN	ExDark	Profundidad	I	+9,63*	+0,37	+0,60	−0,45	Refutada (predecía transferencia)
H17	RetinaNet	ExDark	Siluetas	I	+6,60*	−2,11	−0,28	−3,77	No detectada (0 de 3)

siluetas en NightOwls ($-16{,}8$ en H4) baja a $-1{,}12$ con épocas fijas (H10-s): refleja el sobreajuste al dominio de la regla de selección.

Especificidad y convención de cajas (análisis posteriores). Restamos a la ganancia en las personas ocluidas la de las no ocluidas de la misma fuente. En 11 de 51 celdas el cambio es más favorable en las ocluidas (IC > 0), a menudo porque las visibles empeoran más, y en 13 menos. De las 6 que pasan, solo las dos del indicador de ExDark son específicas, y ninguna resiste el IC jerárquico; en H10 y H10-s, las personas visibles de CityPersons ganan más. Puntuando CityPersons con la caja *visible* en lugar de la completa, la ganancia absoluta en *heavy* baja en casi todos los bloques y no supera +1,3 en ninguno (H10: +2,37 $\rightarrow$ +0,05), aunque el AP de V1 también se reduce a la mitad y en términos relativos la caída es menor (H15: del 15 % al 11 %): parte de lo ganado en *heavy* es estimar la extensión completa de la persona.

Detector, dominio y datos. El patrón se repite con RT-DETR-l (H8), YOLO26s y YOLOv11m (H12), que aprende el aumento con más fuerza que YOLOv11s y no lo traslada. Faster R-CNN con siluetas (H15) cumple la regla prerregistrada en NightOwls (+3,28 [+1,64; +4,79]) y CityPersons (+2,33 [+1,01; +3,69]), pero el resultado es frágil: con la varianza entre semillas sus IC son amplios (t de Welch: $[-0{,}14;\ +6{,}71]$ y $[-0{,}86;\ +5{,}52]$; con varianza combinada, el de NightOwls excluye el cero); en NightOwls ganan más las personas sin oclusión (+4,37); en CityPersons la especificidad es +1,45 $[-0{,}04;\ +3{,}08]$ y con la caja visible la ganancia baja a +0,74 [+0,04; +1,41]; y la tasa de fallos MR^{-2} mejora menos de 2 pp. Bajo el nulo y suponiendo celdas independientes cabría esperar 1,1 pases de 51 (hay 6) y que algún bloque llegue a 2 de 3 con probabilidad 0,03: H15 difícilmente es solo azar, aunque no sea robusto ni propio de la oclusión. Las dos pruebas preespecificadas para acotarlo fallan: con difusión y profundidad (H16a y H16b), Faster R-CNN aprende el aumento (+20,35 y +9,63) y no lo traslada (ninguna celda real supera +0,92), y RetinaNet con siluetas (H17), de una etapa con pérdida focal y la misma red, tampoco (0 de 3). Dos salvedades: las V1 de H16 vienen de otra máquina, y una réplica de V1 allí difirió $-0{,}87$, $-1{,}92$ y +3,42 pp en las tres fuentes (con ella como base, H16 sigue por debajo de +1,3); y la V3 de RetinaNet empeora en todos los estratos ($-6{,}7$ sin oclusión en NightOwls), de modo que un V3 peor ajustado es una explicación alternativa. El déficit no se debe solo al cambio de dominio: dentro de CityPersons (H6, H11), los controles ganan +23,74 y +24,66 y *heavy* +1,82 y +1,31; y los modelos entrenados en ExDark ganan sobre siluetas pegadas en imágenes de CityPersons (9 de 15 bloques pasan, mediana +2,4, aunque con AP de V1 de 0,01 a 0,03 y menos que en ExDark: el dominio también resta) y no sobre la oclusión real de esas imágenes (mediana +0,25; análisis posterior).

Oclusor y matriz cruzada. Ni la difusión (H9, H9b), ni la geometría real (H10), ni la profundidad (H14) cumplen la regla. En la matriz cruzada, pasan 13 de 20 celdas: las siluetas suben +15,8 en el control de geometría y la profundidad +11,7, mientras los parches y la difusión se quedan casi en su propio control (difusión: +0,4, +1,9 y +0,7 en tres de los demás). En Faster R-CNN, medidas sobre un control común (siluetas o geometría), las ganancias sintéticas de H15, H16b y H16a (+14,7, +8,6 y +0,5 en siluetas) siguen el orden de sus ganancias en CityPersons, aunque no con los controles de difusión o profundidad.

Asociación y realismo (análisis posteriores). La asociación entre la ganancia sintética de cada bloque, medida en su

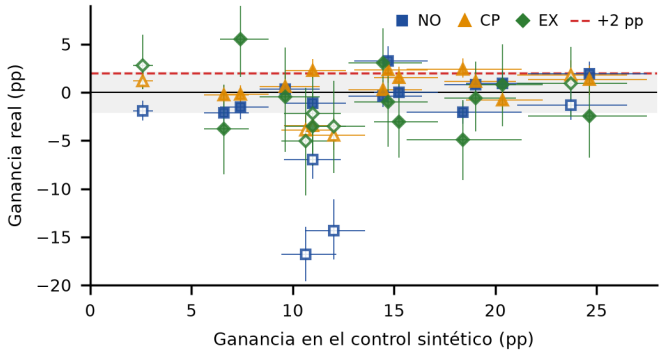


Figura 1. Ganancia en el control sintético frente a la ganancia en cada fuente real, con IC del 95 % por imágenes (17 bloques; rellenos: exposición igual; vacíos: desigual o temprana; H3, con +60,9 en el control, queda fuera de escala). Banda gris: ±2 pp. ρ de Spearman con IC *bootstrap* de bloques, con los 17 bloques: NO +0,37 [−0,11; +0,75], CP +0,24 [−0,21; +0,62], EX −0,05 [−0,55; +0,51]; con exposición igual (11), NO +0,63 [0,00; +1,00].

propio control, y la real no es concluyente: con exposición igual, en NightOwls $\rho = +0{,}63$ [0,00; +1,00] (fig. 1). Con un control de cobertura 0,35–0,70, como *heavy*, los 15 bloques entrenados en ExDark pasan (+2,1 a +33,6), y la asociación con las ganancias reales tampoco es positiva (ρ de $-0{,}11$ a $-0{,}01$, $n = 15$). Para el realismo (H13, parcialmente confirmada), un clasificador lineal sobre DINOv2 [**?**] distingue las personas realmente ocluidas de CityPersons de las ocluidas con cada familia (AUC 0,935–0,993, $n = 400$) mejor que de las mismas sin ocluir (0,876), y CLIP [**?**] coincide; sobre la región ocluida, la distancia KID [**?**] (sin escalar) no acerca ninguna familia al oclusor real. Entrenar en CityPersons lleva su *heavy* a 0,59, frente a 0,24 como máximo sin entrenar allí (comparación descriptiva, no controlada).

Mecanismo (exploratorio). Con el aumento baja la exhaustividad (*recall*) sobre los peatones ocluidos de NightOwls en todos los bloques con diagnóstico, y con siluetas y difusión bajan también los falsos positivos: los modelos pierden personas ocluidas con más confianza, un fallo silencioso para la vigilancia.

V. Discusión

Los resultados coinciden con Taori et al. [**?**] y Pytel et al. [**?**]: lo ganado frente a una perturbación sintética casi no pasa a la real. No contradicen a Kassaw et al. [**?**]: la oclusión sintética puede ordenar modelos y no bastar como señal de entrenamiento. Como en Hendrycks et al. [**?**] y Mintun et al. [**?**], el traslado depende del par aumento-prueba: el único bloque que cumple la regla (Faster R-CNN con siluetas) no se repite con otros oclusores ni con RetinaNet, y su ganancia es frágil entre semillas, no es propia de la oclusión y, en CityPersons, consiste en parte en extender la caja de personas parcialmente visibles, algo que una cabeza por regiones podría aprender [**?**]. Que pasar el control no baste es compatible con un atajo [**?**]: el oclusor artificial sigue siendo distinguible del real (H13), aunque no se ha probado de forma confirmatoria. No refutamos las arquitecturas composicionales [**?**], [**?**], la supervisión amodal [**?**] ni la adaptación de dominio [**?**].

Limitaciones. *De arquitectura:* seis detectores y un solo detector de dos etapas, con una red base; RetinaNet usa otra tasa y otra pérdida, y las V1 de H16 vienen de otra máquina. *De los datos:* casi toda la oclusión real está en conjuntos distintos del de entrenamiento; CityPersons es diurna, NightOwls se graba desde un vehículo y el indicador de ExDark solo capta oclusión entre personas; se evalúa a 640 px; todo es AP@0.5 de una clase. *Del protocolo:* tres semillas (cinco en la extensión), con un IC jerárquico que las subestima; 51 celdas sin corrección por multiplicidad que comparten líneas base; exposición desigual en los primeros bloques; la huella no tiene sello de un tercero, y el realismo se midió en espacios de características.

Líneas futuras. (1) Oclusión tomada de imágenes reales y supervisión amodal [**?**]. (2) Adaptación de dominio para la noche [**?**] y arquitecturas por partes [**?**]. (3) Video real de vigilancia nocturna anotado por visibilidad, con rastreo: ByteTrack [**?**] y BoT-SORT [**?**] sostienen la identidad durante una oclusión breve recuperando cajas de baja confianza, pero solo si el detector las emite. (4) Repetir H15–H17 con más semillas, V1 y V3 en la misma máquina y la receta igualada. Para la práctica: un control sintético sirve para comprobar que un aumento se aprendió, pero afirmar robustez exige oclusión real anotada del dominio de uso y medir la especificidad.

VI. Conclusión

En 18 bloques con cinco tipos de oclusor, seis detectores y tres dominios de entrenamiento, el aumento sintético de oclusión mejoró siempre la detección sobre oclusión sintética. Sobre oclusión real, con exposición igual, la ganancia media fue de +1 pp en CityPersons, nula en NightOwls y no concluyente en ExDark, y la única combinación que cumplió la regla, Faster R-CNN con siluetas, no resistió la varianza entre semillas, la especificidad ni la caja visible. En detección de personas con aumento a nivel de píxel y ajuste fino desde COCO, pasar un control sintético no basta para afirmar robustez a la oclusión real: hace falta oclusión real anotada, V1 y V3 en la misma máquina y un criterio de especificidad.

Declaraciones

Datos y código. Código, registros, huellas, listas de muestreo y suplemento en https://github.com/jhanrq8888/argos-occlusion-transfer (público); los pesos entrenados se depositarán con DOI en Zenodo al publicarse. **Financiamiento:** ninguno. **Conflicto de intereses:** ninguno. **Contribuciones (CRediT):** J. L. Ramos Quispe: conceptualización, metodología, software, análisis formal, investigación, curación de datos y redacción del borrador; C. P. Apaza Hilasaca: conceptualización, metodología (diseño del prerregistro), revisión y edición; B. R. Condori Quispe: curación de datos, validación, visualización, revisión y edición. **Uso de IA:** los autores usaron Scopus AI (Elsevier) para apoyar la búsqueda de los artículos semilla, y Claude (Anthropic) para la búsqueda, el código de análisis y la redacción y edición del texto. Revisaron y verificaron el código, los resultados, las referencias y el texto, de los que asumen la responsabilidad.

REFERENCIAS

[1] P. Dollár, C. Wojek, B. Schiele, and P. Perona, "Pedestrian detection: An evaluation of the state of the art," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 34, no. 4, pp. 743–761, 2012.

[2] Y. P. Loh and C. S. Chan, "Getting to know low-light images with the exclusively dark dataset," *Comput. Vis. Image Underst.*, vol. 178, pp. 30–42, 2019.

[3] Z. Zhong, L. Zheng, G. Kang, S. Li, and Y. Yang, "Random erasing data augmentation," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 7, 2020, pp. 13 001–13 008.

[4] C. Shang, H. Ai, Z. Zhuang *et al.*, "Improving pedestrian detection in crowds with synthetic occlusion images," in *Proc. IEEE Int. Conf. Multimedia Expo Workshops (ICMEW)*, 2018, pp. 1–4.

[5] C. Chi, S. Zhang, J. Xing, Z. Lei, S. Z. Li, and X. Zou, "PedHunter: Occlusion robust pedestrian detector in crowded scenes," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 7, 2020, pp. 10 639–10 646.

[6] S. Shao, Z. Zhao, B. Li, T. Xiao, G. Yu, X. Zhang, and J. Sun, "CrowdHuman: A benchmark for detecting human in a crowd," arXiv:1805.00123, 2018.

[7] S. Zhang, L. Wen, X. Bian, Z. Lei, and S. Z. Li, "Occlusion-aware R-CNN: Detecting pedestrians in a crowd," in *Computer Vision – ECCV 2018*, ser. Lecture Notes in Computer Science. Springer, 2018, pp. 657–674.

[8] C. Zhou and J. Yuan, "Bi-box regression for pedestrian detection and occlusion estimation," in *Computer Vision – ECCV 2018*, ser. Lecture Notes in Computer Science. Springer, 2018, pp. 138–154.

[9] X. Song, B. Chen, P. Li, B. Wang, and H. Zhang, "PRNet++: Learning towards generalized occluded pedestrian detection via progressive refinement network," *Neurocomputing*, vol. 482, pp. 98–115, 2022.

[10] R. Huan, J. Zhang, C. Xie, R. Liang, and P. Chen, "MLFFCSP: A new anti-occlusion pedestrian detection network with multi-level feature fusion for small targets," *Multimedia Tools and Applications*, vol. 82, no. 19, pp. 29 405–29 430, 2023.

[11] K. Yi, K. Luo, T. Chen, and R. Hu, "An improved YOLOX model and domain transfer strategy for nighttime pedestrian and vehicle detection," *Applied Sciences*, vol. 12, no. 23, 2022, art. no. 12476.

[12] G. Ghiasi, Y. Cui, A. Srinivas, R. Qian, T.-Y. Lin, E. D. Cubuk, Q. V. Le, and B. Zoph, "Simple copy-paste is a strong data augmentation method for instance segmentation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 2917–2927.

[13] X. Wang, A. Shrivastava, and A. Gupta, "A-Fast-RCNN: Hard positive generation via adversary for object detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 3039–3048.

[14] C. Michaelis, B. Mitzkus, R. Geirhos, E. Rusak, O. Bringmann, A. S. Ecker, M. Bethge, and W. Brendel, "Benchmarking robustness in object detection: Autonomous driving when winter is coming," arXiv:1907.07484, 2019.

[15] R. Taori, A. Dave, V. Shankar, N. Carlini, B. Recht, and L. Schmidt, "Measuring robustness to natural distribution shifts in image classification," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020.

[16] D. Hendrycks, S. Basart, N. Mu, S. Kadavath, F. Wang, E. Dorundo, R. Desai, T. Zhu, S. Parajuli, M. Guo, D. Song, J. Steinhardt, and J. Gilmer, "The many faces of robustness: A critical analysis of out-of-distribution generalization," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2021, pp. 8320–8329.

[17] E. Mintun, A. Kirillov, and S. Xie, "On interaction between augmentations and corruptions in natural corruption robustness," arXiv:2102.11273, 2021.

[18] K. Kassaw, F. Luzi, L. M. Collins, and J. M. Malof, "Are deep learning models robust to partial object occlusion in visual recognition tasks?" *Pattern Recognition*, vol. 171, p. 112215, 2026.

[19] R. Pytel, O. S. Kayhan, and J. C. van Gemert, "Tilting at windmills: Data augmentation for deep pose estimation does not help with occlusions," in *Proc. 25th Int. Conf. Pattern Recognit. (ICPR)*, 2021, pp. 10 568–10 575.

[20] A. Kortylewski, J. He, Q. Liu, and A. L. Yuille, "Compositional convolutional neural networks: A deep architecture with innate robustness to partial occlusion," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 8937–8946.

[21] A. Wang, Y. Sun, A. Kortylewski, and A. Yuille, "Robust object detection under occlusion with context-aware CompositionalNets," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 12 642–12 651.

[22] N. D. Reddy, R. Tamburo, and S. G. Narasimhan, "WALT: Watch and learn 2D amodal representation from time-lapse imagery," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 9346–9356.

[23] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, and F. A. Wichmann, "Shortcut learning in deep neural networks," *Nat. Mach. Intell.*, vol. 2, no. 11, pp. 665–673, 2020.

[24] I. Hasan, S. Liao, J. Li, S. U. Akram, and L. Shao, "Generalizable pedestrian detection: The elephant in the room," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 11 323–11 332.

[25] V. S. Sukesh Babu and R. Raman, "Robust pedestrian detection via curated training on created dataset," in *Proc. IEEE 21st India Council Int. Conf. (INDICON)*, 2024.

[26] Z. Cui, G.-J. Qi, L. Gu, S. You, Z. Zhang, and T. Harada, "Multitask AET with orthogonal tangent regularity for dark object detection," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2021, pp. 2553–2562.

[27] L. Neumann, M. Karg, S. Zhang, C. Scharfenberger, E. Piegert, S. Mistr, O. Prokofyeva, R. Thiel, A. Vedaldi, A. Zisserman, and B. Schiele, "NightOwls: A pedestrians at night dataset," in *Computer Vision – ACCV 2018*, ser. Lecture Notes in Computer Science, vol. 11361, 2019, pp. 691–705.

[28] S. Zhang, R. Benenson, and B. Schiele, "CityPersons: A diverse dataset for pedestrian detection," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, pp. 3213–3221.

[29] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 10 674–10 685.

[30] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 37, 2024.

[31] Ultralytics, "Ultralytics YOLO11 documentation," https://docs.ultralytics.com, 2024, accessed: Jun. 2026.

[32] ——, "Ultralytics YOLO26," https://docs.ultralytics.com/models/yolo26/, 2026, consultado el 20 oct. 2026.

[33] Y. Zhao, W. Lv, S. Xu, J. Wei, G. Wang, Q. Dang, Y. Liu, and J. Chen, "DETRs beat YOLOs on real-time object detection," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2024, pp. 16 965–16 974.

[34] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 39, no. 6, pp. 1137–1149, 2017.

[35] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 2999–3007.

[36] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: common objects in context," in *Computer Vision – ECCV 2014*, ser. Lecture Notes in Computer Science, vol. 8693, 2014, pp. 740–755.

[37] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall/CRC, 1993.

[38] D. Lakens, "Equivalence tests: A practical primer for t tests, correlations, and meta-analyses," *Soc. Psychol. Personal. Sci.*, vol. 8, no. 4, pp. 355–362, 2017.

[39] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov *et al.*, "DINOv2: Learning robust visual features without supervision," *Trans. Mach. Learn. Res.*, 2024.

[40] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal *et al.*, "Learning transferable visual models from natural language supervision," in *Proc. 38th Int. Conf. Mach. Learn. (ICML)*, ser. PMLR, vol. 139, 2021, pp. 8748–8763.

[41] M. Bińkowski, D. J. Sutherland, M. Arbel, and A. Gretton, "Demystifying MMD GANs," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2018.

[42] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu, and X. Wang, "ByteTrack: Multi-object tracking by associating every detection box," in *Computer Vision – ECCV 2022*, ser. Lecture Notes in Computer Science, vol. 13682. Springer, 2022, pp. 1–21.

[43] N. Aharon, R. Orfaig, and B.-Z. Bobrovsky, "BoT-SORT: Robust associations multi-pedestrian tracking," arXiv:2206.14651, 2022.